



# Universidad Europea

**UNIVERSIDAD EUROPEA DE MADRID**

**ESCUELA DE ARQUITECTURA, INGENIERÍA Y DISEÑO**

**GRADO EN INGENIERIA INFORMÁTICA**

**PROYECTO COMPUTACIÓN I**

**TrafiVision**

**Grupo 5**

**Anyi Lin**

**Rodrigo DÍAZ MARTÍNEZ**

**Dirigido por**

**MIQUEL COLOBRAN HUGUET**

**CURSO 2025-2026**

**TÍTULO:** TrafiVisión

**AUTOR:** Anyi Lin,Rodrigo DÍAZ MARTÍNEZ

**TITULACIÓN:** GRADO EN INGENIERÍA INFORMÁTICA

**DIRECTOR/ES DEL PROYECTO:** MIQUEL COLOBRAN HUGUET

**FECHA:** Enero 2026

**REPOSITORIO:** <https://github.com/RodrigoVII/TrafiVison>

## RESUMEN

El resumen tiene entre 150-250 palabras. Resumir consiste en ofrecer información sobre cómo, dónde, cuándo y por qué se aplica el proyecto. Se realiza al finalizar el trabajo.

Debe incluir:

- Resumen del problema planteado y las aportaciones más importantes del proyecto al respecto
- Indica si procede si el proyecto se realizó en colaboración con una empresa, indicando nombre (siempre que haya autorización expresa por la empresa), y el sector industrial o empresarial
- Principales resultados del proyecto (diseño de un sistema para..., desarrollo e implementación de una solución para..., análisis de..., modelo de...)
- Resume las conclusiones más importantes del trabajo realizado

**Palabras clave:** hasta un máximo de 6 conceptos (un concepto puede conllevar una o más palabras). Incluye tecnologías que hayas utilizado, conceptos relevantes del ámbito científico-técnico, y conceptos de la industria (algunos ejemplos: machine learning, Big Data, Smart City, visión artificial, social media, Twitter, computación afectiva, transformación digital, GDPR, DevOps, EEG, ...)

# ABSTRACT

Resumen en inglés.

**Keywords:** Palabras clave en inglés

# INDICE

|                                                                 |           |
|-----------------------------------------------------------------|-----------|
| <b>RESUMEN.....</b>                                             | <b>3</b>  |
| <b>ABSTRACT.....</b>                                            | <b>4</b>  |
| <b>Capítulo 1. INTRODUCCIÓN.....</b>                            | <b>8</b>  |
| 1.1 Estado del arte.....                                        | 9         |
| 1.2 Contexto y justificación.....                               | 10        |
| 1.3 Objetivos generales.....                                    | 11        |
| 1.4 Objetivos específicos.....                                  | 12        |
| <b>1.5 Planificación.....</b>                                   | <b>14</b> |
| <b>Capítulo 2. TECNOLOGÍAS USADAS.....</b>                      | <b>15</b> |
| <b>Capítulo 3. ANALISIS DEL PROBLEMA.....</b>                   | <b>18</b> |
| Análisis del problema.....                                      | 22        |
| <b>Capítulo 4. PROPUESTA DE SOLUCIÓN (DISEÑO).....</b>          | <b>28</b> |
| 4.1 Organización de las subtarear.....                          | 29        |
| Organización de subtarear.....                                  | 30        |
| <b>Capítulo 5. DESARROLLO / IMPLEMENTACIÓN.....</b>             | <b>35</b> |
| <b>Capítulo 6. Modelado.....</b>                                | <b>37</b> |
| Modelado.....                                                   | 37        |
| Capítulo 7. BIBLIOGRAFIA/WEBGRAFIA.....                         | 46        |
| <b>Capítulo 8. ANEXOS.....</b>                                  | <b>48</b> |
| ANEXO I – Criterios de clasificación y variables derivadas..... | 48        |

# Índice de Figuras

Todas las figuras incluidas en la memoria deben estar referenciadas para incluir en este índice.

# Índice de Tablas

Todas las tablas incluidas en la memoria deben estar referenciadas para incluir en este índice.

# Capítulo 1. INTRODUCCIÓN

El proyecto **TrafiVison** tiene como objetivo desarrollar un sistema automatizado de recopilación, integración y análisis de datos de tráfico urbano en la ciudad de Madrid. El enfoque adoptado se basa en la implementación de un proceso **ETL (Extracción, Transformación y Carga)** capaz de combinar información visual procedente de cámaras públicas de tráfico con datos meteorológicos obtenidos a través de la plataforma **Open-Meteo**, generando un conjunto de datos estructurado y preparado para su análisis y modelado.

En la fase actual, el sistema es capaz de **extraer imágenes en tiempo real** desde distintas ubicaciones estratégicas de la ciudad, registrar de forma precisa su fecha y hora, y asociar a cada captura las condiciones meteorológicas correspondientes, como la temperatura, la precipitación y el tipo de lluvia. Sobre estas imágenes se aplica un modelo de **visión por computador basado en YOLOv8**, que permite detectar vehículos y clasificar automáticamente el nivel de tráfico en tres categorías: **bajo, medio y elevado**. Toda esta información se consolida en un **dataset unificado y limpio en formato CSV**, que constituye la base del sistema de análisis.

El trabajo realizado se ha centrado en garantizar la **calidad, coherencia temporal y consistencia estructural de los datos**, abordando y corrigiendo incidencias detectadas durante las primeras fases de ejecución, como errores en el formato de la hora o pequeños desfases temporales entre la captura de imágenes y los datos meteorológicos asociados. Este proceso de depuración ha permitido obtener un conjunto de datos fiable y adecuado para su uso en técnicas de aprendizaje automático.

A partir del dataset generado, se ha llevado a cabo una fase de **modelado predictivo**, utilizando algoritmos de clasificación supervisada para estimar el nivel de tráfico en función de variables temporales, espaciales y meteorológicas, tales como la franja horaria, el carácter laborable del día, la ubicación de la cámara o las condiciones climáticas. El proceso de entrenamiento y validación de los modelos se ha realizado mediante la



herramienta **Altair AI Studio**, permitiendo comparar distintos enfoques y seleccionar el modelo con mejor rendimiento global.

Como resultado, el sistema desarrollado demuestra que es posible **predecir el nivel de tráfico urbano** a partir de datos abiertos y procesos automatizados, incluso con un volumen de datos limitado, sentando una base sólida para su ampliación y mejora en entornos reales.

Como fase final del proyecto, se prevé el desarrollo de una **aplicación visual sencilla en Python** que permita interactuar con el modelo predictivo entrenado. Esta herramienta estaría orientada a la consulta del sistema, facilitando la selección de distintos parámetros de entrada —como la calle, la franja horaria, el tipo de día o las condiciones meteorológicas— y mostrando como resultado la **estimación del nivel de tráfico** correspondiente. De este modo, el proyecto no solo aborda el análisis y modelado de datos, sino que avanza hacia una solución práctica y accesible para la toma de decisiones en el ámbito de la movilidad urbana.

## 1.1 Estado del arte

En los últimos años, diferentes organismos públicos han puesto a disposición de la ciudadanía **datos abiertos sobre movilidad y tráfico urbano**, permitiendo el desarrollo de proyectos que combinan información visual, meteorológica y de sensores para comprender mejor la congestión vial. En el caso de Madrid, el **Ayuntamiento** ofrece un sistema de **cámaras de tráfico en tiempo real**, accesibles de forma pública, y diversas **APIs de datos abiertos** que incluyen información sobre el estado de las vías, incidencias o intensidad de circulación.

Pese a ello, la mayor parte de estos datos se encuentran **dispersos, en formatos heterogéneos y con frecuencias de actualización variables**, lo que dificulta su aprovechamiento conjunto. De manera similar, las fuentes meteorológicas —como las proporcionadas por **Open-Meteo o AEMET**— suelen mantenerse separadas del resto de los sistemas de información de tráfico, reduciendo las posibilidades de correlacionar factores ambientales con los niveles de congestión.

Hasta el momento, la mayoría de proyectos existentes se centran en **visualizar tráfico en tiempo real o mostrar cámaras en mapas interactivos**, pero pocos abordan la **automatización del proceso ETL completo** (Extracción, Transformación y Carga) que permita mantener un **dataset limpio y normalizado** de forma continua. Este tipo de integración es esencial para garantizar la **consistencia temporal y la calidad de los datos** cuando se pretende entrenar modelos de aprendizaje automático.

En este contexto, **TrafiVison** surge como una propuesta práctica y académica que busca **automatizar la recogida y estandarización** de datos de tráfico en Madrid, **fusionando imágenes, información meteorológica y variables temporales** (hora, día de la semana, laborable/festivo). En esta primera fase, el sistema se centra en construir un dataset propio y verificable; en etapas futuras, se prevé extenderlo hacia la **predicción de niveles de tráfico y visualización de patrones de movilidad**.

## 1.2 Contexto y justificación

El análisis de datos abiertos relacionados con el tráfico se ha convertido en una herramienta esencial para **mejorar la movilidad urbana, reducir la congestión y optimizar la planificación del transporte público y privado**. Sin embargo, la información disponible suele proceder de **fuentes heterogéneas**, con distintos formatos, niveles de actualización y estructuras, lo que **complica su integración y análisis conjunto**.

En este contexto, el proyecto **TrafiVison** nace con el propósito de **unificar y automatizar la recopilación de datos de tráfico y clima en la ciudad de Madrid**, creando un flujo ETL (Extracción, Transformación y Carga) que garantice la coherencia y la trazabilidad de la información. El sistema combina imágenes captadas desde cámaras públicas del Ayuntamiento de Madrid con datos meteorológicos en tiempo real de la API **Open-Meteo**, generando un dataset propio, estructurado y limpio, listo para ser utilizado en futuros análisis.

Desde el punto de vista **académico**, TrafiVison representa un **caso práctico de aplicación de técnicas de ingeniería de datos** dentro del ámbito de la inteligencia artificial y el aprendizaje automático, abordando todas las etapas del ciclo de vida de los datos: obtención, limpieza, integración y validación.

En el plano **social y tecnológico**, el proyecto contribuye al **aprovechamiento de los datos abiertos** como herramienta de conocimiento, fomentando la transparencia y la innovación en la gestión de la movilidad urbana. A largo plazo, TrafiVison busca sentar las bases para el desarrollo de **modelos predictivos** que ayuden a anticipar niveles de tráfico y a diseñar estrategias de movilidad más sostenibles y seguras.

### 1.3 Objetivos generales

El objetivo principal del proyecto TrafiVison es diseñar e implementar un proceso ETL (Extracción, Transformación y Carga) que integre datos abiertos de tráfico y condiciones meteorológicas para generar un dataset propio, limpio y estructurado, capaz de servir como base para el análisis y la predicción del comportamiento del tráfico urbano en la ciudad de Madrid.

En su estado actual, el proyecto cuenta con un proceso completo de extracción y transformación de datos, en el que se han automatizado los siguientes componentes:

- La descarga periódica de imágenes procedentes de diez cámaras públicas de tráfico del Ayuntamiento de Madrid.
- La recopilación de datos meteorológicos en tiempo real mediante la API Open-Meteo.
- El análisis automatizado de las imágenes capturadas mediante el modelo de visión por computador YOLOv8, que permite detectar vehículos y clasificar el nivel de tráfico en categorías bajo, medio y elevado.

Durante la fase de transformación, se ha desarrollado un proceso de limpieza, integración y estandarización de los datos, resolviendo incidencias como errores en el formato de la hora o desajustes temporales entre las capturas de las cámaras y los datos meteorológicos. Como resultado, se ha obtenido un dataset funcional y coherente, en formato CSV, que integra información visual, meteorológica y etiquetas de tráfico.

A partir de este conjunto de datos, se ha llevado a cabo una fase de modelado predictivo mediante técnicas de aprendizaje automático, permitiendo estimar el nivel de tráfico en función de variables como la hora del día, la franja horaria, la ubicación de la cámara, la temperatura, la precipitación y el carácter laborable del día.

Como líneas de evolución del proyecto, se contempla la ampliación del volumen y la diversidad del conjunto de datos, incorporando nuevos periodos temporales, condiciones meteorológicas y ubicaciones, así como el desarrollo de una interfaz visual que facilite la consulta de los resultados y el análisis de tendencias de congestión.

En conjunto, TrafiVisión demuestra cómo la combinación de datos abiertos, visión por computador y procesos ETL automatizados permite desarrollar herramientas útiles para el estudio del tráfico urbano y el apoyo a la toma de decisiones en el ámbito de la movilidad.

## **1.4 Objetivos específicos**

1. Analizar y evaluar fuentes de datos abiertas relacionadas con el tráfico urbano y las condiciones meteorológicas, priorizando aquellas que sean accesibles, actualizadas y fiables.

En el desarrollo del proyecto se han seleccionado las cámaras públicas de tráfico del Ayuntamiento de Madrid y la API Open-Meteo, debido a su disponibilidad, fiabilidad y formato estructurado. Como línea de evolución, se contempla la incorporación de fuentes complementarias, como datos de aforos o información de congestión procedente de otros portales

de datos abiertos.


2. Desarrollar scripts de extracción automatizados que permitan obtener los datos de forma periódica y sin intervención manual.  
Actualmente, el sistema captura imágenes de tráfico y datos meteorológicos de manera sincronizada cada quince minutos. Esta automatización permite la generación continua del dataset y asegura la coherencia temporal entre las distintas fuentes. En fases posteriores, se prevé ampliar los periodos de captura y añadir mecanismos de monitorización y registro de errores.
3. Estandarizar, depurar y enriquecer la información recopilada para garantizar su consistencia y calidad.  
Durante esta fase se han corregido errores de formato, como la denominada "hora fantasma", se han eliminado duplicados y se han incorporado variables derivadas, entre ellas el carácter laborable del día y la franja horaria. Estas transformaciones permiten mejorar la calidad del conjunto de datos y facilitar su posterior análisis.
4. Unificar la información procedente de las distintas fuentes en un dataset estructurado y documentado, preparado para su análisis y modelado.  
El dataset resultante (`dataset_final_limpio.csv`) integra información visual, meteorológica y temporal, y permite explorar relaciones entre el tráfico, el clima y el momento del día. Como mejora futura, se plantea la elaboración de un diccionario de datos completo, la inclusión de metadatos descriptivos y la evaluación de otros formatos de almacenamiento para facilitar su reutilización.
5. Aplicar técnicas de aprendizaje automático para el análisis y la predicción del nivel de tráfico urbano.  
A partir del dataset generado, se ha llevado a cabo un proceso de modelado mediante algoritmos de clasificación supervisada, orientado a estimar el nivel de tráfico en función de variables

espaciales, temporales y meteorológicas. Este proceso permite evaluar distintos enfoques y seleccionar el modelo con mejor rendimiento para su uso en el sistema.

6. Facilitar el análisis de patrones de movilidad y tráfico mediante la interpretación de los resultados obtenidos.

El sistema desarrollado permite identificar tendencias de congestión asociadas a determinadas franjas horarias, ubicaciones y condiciones climáticas, constituyendo una base sólida para futuras visualizaciones y herramientas de apoyo a la toma de decisiones.

## 1.5 Planificación



## Capítulo 2. TECNOLOGÍAS USADAS

El desarrollo del proyecto TrafiVisión se apoya en un conjunto de herramientas y tecnologías que permiten automatizar la recopilación, el tratamiento, el análisis y el modelado de datos de tráfico urbano. A continuación, se describen las principales tecnologías empleadas a lo largo del proyecto.

### **Python 3.9**

Python constituye el lenguaje principal del sistema debido a su versatilidad, amplia comunidad y disponibilidad de bibliotecas especializadas en manipulación de datos, visión por computador y aprendizaje automático.

Todo el flujo ETL del proyecto —incluyendo la extracción, limpieza, integración y generación del dataset final— se ha implementado íntegramente en Python.

### **Visual Studio Code**

El entorno de desarrollo utilizado es Visual Studio Code, que facilita la organización del proyecto, la ejecución de scripts desde la terminal y la integración con sistemas de control de versiones. Su uso permite mantener una estructura clara del código y una trazabilidad completa de los cambios realizados durante el desarrollo.

### **Bibliotecas de Python**

El proyecto hace uso de diversas bibliotecas especializadas, entre las que destacan:

- requests, para realizar peticiones HTTP a las fuentes de datos, incluyendo las cámaras de tráfico y la API de Open-Meteo.
- pandas, para la manipulación, limpieza, unión y exportación de los conjuntos de datos en formato CSV.
- schedule, time y datetime, utilizadas para la automatización de tareas periódicas y la gestión de fechas y horas.

- ultralytics (YOLOv8), empleada para la detección de vehículos en imágenes mediante técnicas de visión por computador. Se ha utilizado el modelo YOLOv8n (nano) por su equilibrio entre precisión y eficiencia.
- opencv-python, utilizada de forma indirecta para el procesamiento de imágenes.
- torch y torchvision, empleadas como base para la ejecución del modelo YOLO y la inferencia de detección de objetos.

### **Open-Meteo API**

La API Open-Meteo se utiliza como fuente principal de información meteorológica. Permite obtener datos de temperatura, precipitación y condiciones climáticas en tiempo real para coordenadas específicas, en este caso correspondientes a la ciudad de Madrid. Se trata de una API gratuita y sin necesidad de autenticación, lo que facilita su integración y automatización dentro del sistema.

### **Cámaras públicas de tráfico del Ayuntamiento de Madrid**

El proyecto emplea imágenes procedentes de cámaras públicas de tráfico actualizadas periódicamente. Se accede directamente a los enlaces en formato JPG de diez cámaras seleccionadas en ubicaciones representativas de la ciudad, como Cibeles, Plaza de Castilla, Gran Vía o Cuatro Caminos. Estas imágenes constituyen la base visual del análisis del tráfico.

### **Altair AI Studio**

Para la fase de modelado y validación de los datos se ha utilizado la herramienta Altair AI Studio. Esta plataforma ha permitido diseñar flujos de aprendizaje automático de forma visual, aplicar técnicas de validación cruzada, comparar distintos algoritmos de clasificación y seleccionar el modelo con mejor rendimiento para la predicción del nivel de tráfico.

### **Git y GitHub**



Git y GitHub se utilizan como herramientas de control de versiones y gestión del proyecto. El repositorio permite almacenar el código, el dataset generado y los artefactos del modelado, facilitando el seguimiento de cambios, la colaboración y la reproducibilidad del sistema desarrollado.

### **Conclusión sobre las tecnologías utilizadas**

La combinación de Python, bibliotecas especializadas, herramientas de visión por computador y plataformas de modelado ha permitido construir un sistema completo, modular y reproducible para el análisis del tráfico urbano. El uso de Altair AI Studio ha facilitado la fase de aprendizaje automático, permitiendo evaluar distintos modelos y seleccionar el más adecuado en función de su rendimiento. En conjunto, las tecnologías empleadas proporcionan una base sólida para el análisis y la predicción del tráfico en entornos urbanos reales.

## Capítulo 3. ANALISIS DEL PROBLEMA

### Necesidad y motivación

La gestión del tráfico en las grandes ciudades constituye un reto constante debido a la elevada densidad de vehículos y a la complejidad de los patrones de movilidad urbana. En el caso de Madrid, el tráfico genera de forma recurrente episodios de congestión, incremento de los tiempos de desplazamiento y un impacto negativo en la calidad del aire, lo que pone de manifiesto la necesidad de disponer de información actualizada y accesible que permita analizar y comprender el comportamiento del tráfico en distintos contextos.

Aunque el Ayuntamiento de Madrid pone a disposición diversas fuentes de datos abiertos, como cámaras de tráfico o información sobre incidencias, estos datos se presentan de forma fragmentada y en formatos heterogéneos, lo que dificulta su integración y su explotación conjunta de manera automatizada. Del mismo modo, las fuentes meteorológicas externas, como Open-Meteo o AEMET, no se encuentran directamente integradas con los datos de tráfico, a pesar de la influencia directa que las condiciones climáticas ejercen sobre la movilidad urbana.

En este contexto, el proyecto TrafiVison aborda la problemática desde un enfoque práctico y orientado a datos, automatizando la recolección, limpieza e integración de información visual y meteorológica. El resultado es la generación de un dataset unificado que combina ambos tipos de información, facilitando su análisis y posterior modelado. De este modo, el proyecto contribuye a mejorar la accesibilidad y el aprovechamiento de los datos abiertos para el estudio técnico del tráfico urbano y para el desarrollo de soluciones basadas en datos que apoyen la toma de decisiones en movilidad.

## **Problemas detectados durante el desarrollo**

Durante las primeras fases del desarrollo del proyecto se identificaron diversos retos técnicos relacionados con la calidad, la coherencia y la integración de los datos, así como con las características propias de las fuentes utilizadas.

Uno de los principales problemas detectados fue la inconsistencia en el formato de la hora. En las primeras capturas, algunas entradas incluían una fecha errónea (1900-01-01), lo que afectaba a la coherencia temporal del conjunto de datos. Esta incidencia se resolvió mediante el desarrollo de un script específico de limpieza que estandariza la información horaria y conserva únicamente el valor correspondiente a la hora en formato HH:MM.

Otro reto relevante fue el desfase temporal entre las capturas de las cámaras de tráfico y los datos meteorológicos asociados. Dado que ambas fuentes no se actualizan de forma perfectamente simultánea, se introdujo una tolerancia temporal de  $\pm 2$  minutos en el proceso de unión de los datos, permitiendo asociar de manera más precisa la información climática a cada imagen capturada.

Asimismo, se detectó un desbalance en la distribución de las muestras, ya que la mayoría de las imágenes recopiladas corresponden a días sin lluvia. Este desequilibrio puede influir en el rendimiento del modelo predictivo, especialmente en la identificación de situaciones menos frecuentes. Aunque el dataset actual es funcional, este aspecto se tiene en cuenta como una limitación del sistema y como un punto de mejora mediante la ampliación de las capturas en condiciones meteorológicas más diversas.

Por último, se identificaron limitaciones relacionadas con las condiciones de iluminación, especialmente en las imágenes nocturnas. La presencia de reflejos, sombras y contrastes elevados dificulta en algunos casos la detección precisa de vehículos por parte del modelo YOLOv8. Para mitigar este efecto, se han ajustado los parámetros de confianza y los filtros aplicados durante el análisis de las imágenes.

Estos problemas se han abordado de forma progresiva a lo largo del desarrollo del proyecto, priorizando en todo momento la calidad del dato, la coherencia temporal y la correcta integración de las distintas fuentes de información.

## Casos de uso actuales y previstos

1. Actualmente, TrafiVisión permite realizar un análisis del comportamiento del tráfico urbano en distintos puntos de la ciudad de Madrid, combinando variables temporales, espaciales y meteorológicas como la hora del día, la temperatura, la presencia de lluvia, la franja horaria y el carácter laborable del día. A partir del dataset generado y del proceso de modelado desarrollado, el sistema da soporte a distintos casos de uso tanto actuales como de evolución futura.
2. En primer lugar, el sistema permite llevar a cabo un análisis exploratorio del tráfico urbano, facilitando el estudio de cómo varía el nivel de congestión en función de la franja horaria, las condiciones meteorológicas o el tipo de día. Este análisis resulta útil para identificar patrones generales de movilidad y comportamientos recurrentes del tráfico.
3. En segundo lugar, TrafiVisión posibilita la comparación entre distintas ubicaciones, permitiendo identificar qué zonas presentan mayores niveles de congestión en determinados horarios o bajo condiciones específicas. Este enfoque comparativo resulta especialmente relevante para analizar diferencias estructurales entre calles y áreas de la ciudad.
4. Además, el proyecto ya sirve como base para la aplicación de modelos predictivos de tráfico. A partir del dataset generado, se ha desarrollado un modelo de clasificación que permite estimar el nivel de tráfico en función de las variables disponibles, constituyendo un primer paso hacia sistemas de predicción más avanzados.
5. Como línea de evolución, se prevé ampliar estos casos de uso mediante el desarrollo de una interfaz visual que permita consultar de forma interactiva las predicciones del modelo, facilitando la introducción de distintas condiciones de entrada y la visualización del nivel de tráfico estimado. De este modo, TrafiVisión evoluciona desde una herramienta de análisis hacia una solución práctica de apoyo a la toma de decisiones en movilidad urbana.

## Requisitos del problema

- Los datos utilizados deben proceder de fuentes oficiales y abiertas, garantizando su fiabilidad y disponibilidad. Asimismo, deben mantenerse actualizados mediante un proceso de recopilación automatizado que no requiera intervención manual.
- El sistema debe asegurar la coherencia temporal entre las imágenes de tráfico y los datos meteorológicos asociados, de forma que cada registro del dataset represente una situación real y consistente.
- El conjunto de datos generado debe presentarse de forma limpia y estructurada, preparado para su análisis mediante técnicas de aprendizaje automático, así como para su posible uso en procesos de visualización y análisis exploratorio.
- El proceso ETL implementado debe ser reproducible y escalable, permitiendo su ejecución periódica y su adaptación a nuevas fuentes de datos o a un mayor volumen de información sin modificaciones sustanciales en su estructura.

## Perspectiva futura

En las siguientes fases de evolución del sistema, el proyecto se orientará principalmente a la **ampliación y diversificación del conjunto de datos ya existente**, incorporando nuevos periodos temporales y una mayor variedad de situaciones dentro de las mismas ubicaciones analizadas. Esta ampliación permitiría mejorar la capacidad de generalización del modelo y reforzar la representación de escenarios menos frecuentes, como condiciones meteorológicas adversas o episodios de tráfico elevado.

Asimismo, se contempla la mejora del proceso de detección de vehículos en condiciones nocturnas, mediante el ajuste de parámetros del modelo de visión por computador y la optimización de los filtros aplicados durante el análisis de imágenes. Estas mejoras permitirían aumentar la fiabilidad de las detecciones en entornos con baja iluminación.

En cuanto al análisis predictivo, el proyecto ya dispone de un modelo de aprendizaje automático capaz de estimar el nivel de tráfico a partir de variables temporales, espaciales y meteorológicas. Como línea de mejora, se prevé optimizar este modelo mediante la incorporación de un mayor volumen de datos y la evaluación de ajustes que permitan mejorar su rendimiento, especialmente en la clasificación de situaciones de alta congestión.

Por último, se plantea el desarrollo de una interfaz visual sencilla que permita interactuar con el modelo predictivo, facilitando la introducción de distintas condiciones de entrada y la consulta del nivel de tráfico estimado. De este modo, TrafiVison evolucionaría hacia una herramienta más accesible y orientada a la interpretación práctica de los resultados obtenidos.

## **Análisis del problema**

### **Necesidad y motivación**

La gestión del tráfico urbano en la ciudad de Madrid representa un desafío constante, especialmente en aquellas zonas con alta densidad de circulación. Las congestiones diarias, el incremento de los tiempos de desplazamiento y el impacto medioambiental asociado al tráfico hacen necesario disponer de datos reales y actualizados que permitan analizar los patrones de movilidad y anticipar situaciones de elevada ocupación vial.

Aunque el Ayuntamiento de Madrid ofrece acceso a múltiples fuentes de datos abiertos, entre ellas las cámaras de tráfico en tiempo real, esta

información suele presentarse de forma dispersa y sin una integración directa con otros factores relevantes, como las condiciones meteorológicas. Esta falta de conexión entre fuentes dificulta la realización de análisis conjuntos que permitan extraer conclusiones útiles sobre el comportamiento del tráfico.

El proyecto TrafiVison se desarrolla con el propósito de unificar y automatizar la recopilación de información visual y meteorológica, generando un conjunto de datos coherente y preparado para su análisis. Para ello, se han seleccionado diez cámaras de tráfico ubicadas en puntos estratégicos de la ciudad, en los que se registran flujos representativos de distintos tipos de vías y entornos urbanos. Las ubicaciones seleccionadas son las siguientes:

- Calle Princesa – Serrano Jover
- Alonso Martínez
- Cibeles
- Calle Alcalá – Velázquez
- Paseo de la Castellana – Santiago Delgado
- Avenida de América – Francisco Silvela
- Callao – Gran Vía
- Cuatro Caminos
- Paseo del Prado – Huertas
- Plaza de Castilla (Norte)

Estas localizaciones combinan zonas céntricas, avenidas principales y ejes de conexión entre distintos barrios, lo que permite capturar una amplia variedad de patrones de tráfico a lo largo del día. Además, la diversidad de ubicaciones garantiza diferentes condiciones de iluminación y entorno,

aspectos relevantes para el entrenamiento y evaluación de modelos de visión por computador.

El sistema desarrollado captura imágenes de estas cámaras de forma periódica cada quince minutos, alineando las capturas a las horas en punto y a los cuartos (:00, :15, :30 y :45). Estas imágenes se combinan con los datos meteorológicos obtenidos mediante la API Open-Meteo, que proporciona información sobre la temperatura y las precipitaciones en la ciudad de Madrid, permitiendo asociar a cada captura de tráfico su contexto climático correspondiente.

## **Problemas detectados durante el desarrollo**

Durante la fase de implementación del sistema se identificaron y resolvieron diversos retos técnicos relacionados con la calidad, coherencia y sincronización de los datos utilizados.

Uno de los principales problemas detectados fue el formato inconsistente de la hora. En las primeras versiones del dataset, los registros incluían la fecha "1900-01-01" junto con la hora, lo que generaba errores durante el proceso de unificación de los archivos CSV. Esta incidencia se resolvió mediante el desarrollo de un script de limpieza que normaliza la información horaria y conserva únicamente el valor de la hora en formato HH:MM.

Otro reto relevante fue el desfase temporal entre las capturas de las cámaras de tráfico y los datos meteorológicos asociados. Dado que la frecuencia de actualización de las cámaras y de la API meteorológica no coincide de forma exacta, se introdujo una tolerancia temporal de  $\pm 2$  minutos en el proceso de unión, permitiendo asociar de manera más precisa la información climática a cada imagen capturada.

Asimismo, se detectó un desbalance en la distribución de los datos, ya que la mayoría de las capturas corresponden a días sin lluvia y a franjas horarias diurnas. Esta representación desigual puede influir en el rendimiento de los modelos predictivos, especialmente en la identificación de situaciones menos



frecuentes. Este aspecto se considera una limitación del dataset actual y un punto de mejora mediante la ampliación temporal de la recolección de datos.

Por último, se observaron limitaciones en la detección de vehículos en condiciones nocturnas. La baja iluminación, la presencia de reflejos y el contraste elevado en determinadas zonas afectan a la precisión del modelo YOLOv8. Para mitigar este efecto, se han evaluado ajustes en los parámetros de detección y la aplicación de filtros adicionales durante el análisis de las imágenes.

En conjunto, estos problemas se abordaron de forma progresiva a lo largo del desarrollo del proyecto, priorizando en todo momento la coherencia temporal y la calidad del dato frente al volumen de información recolectada.

## **Casos de uso actuales y previstos**

1. En su estado actual, TrafiVisión permite realizar un análisis del comportamiento del tráfico urbano en distintos puntos de la ciudad de Madrid, a partir de la integración de información visual, temporal y meteorológica. El sistema da soporte a varios casos de uso relevantes tanto en la fase actual como en su posible evolución.
2. En primer lugar, permite llevar a cabo un análisis exploratorio del tráfico, facilitando el estudio de cómo varía la intensidad del tráfico en función de la hora del día, la ubicación de la cámara y las condiciones meteorológicas. Este análisis resulta útil para identificar patrones recurrentes y franjas horarias con mayor o menor congestión.
3. Asimismo, el sistema posibilita la comparación entre distintas zonas de la ciudad, permitiendo observar diferencias de ocupación entre calles céntricas, como Gran Vía o Cibeles, y zonas de conexión o acceso, como Plaza de Castilla o Cuatro Caminos. Este enfoque comparativo contribuye a comprender mejor el comportamiento diferencial del tráfico según el tipo de vía y su función dentro de la red urbana.

4. Además, TrafiVisión ya actúa como base para la predicción del nivel de tráfico, al contar con un dataset preparado y un modelo de aprendizaje automático capaz de estimar la categoría de tráfico en función de variables temporales y meteorológicas. Este uso constituye un primer paso hacia sistemas más avanzados de apoyo a la toma de decisiones en movilidad urbana.
5. Como línea de evolución, estos casos de uso podrían ampliarse mediante herramientas de visualización o interfaces de consulta que faciliten la interpretación de los resultados y el acceso a las predicciones de forma más intuitiva.

## **Requisitos del problema**

- Los datos utilizados deben ser reales, abiertos y proceder de fuentes oficiales, garantizando su fiabilidad y disponibilidad. Asimismo, su obtención debe realizarse de forma automatizada, sin intervención manual.
- El proceso ETL debe ejecutarse de manera periódica y reproducible, permitiendo la actualización continua del conjunto de datos y asegurando la consistencia del sistema a lo largo del tiempo.
- La información temporal debe mantenerse sincronizada entre las capturas de las cámaras de tráfico y los datos meteorológicos asociados, de modo que cada registro represente una situación real y coherente.
- El dataset final generado debe ser limpio, estructurado y coherente, y estar preparado para su uso en análisis estadísticos, visualización de datos y modelos predictivos de aprendizaje automático.

## **Perspectiva futura**

En fases posteriores de evolución del sistema, se plantea ampliar el periodo de observación utilizando la misma infraestructura actual, con el objetivo de incorporar un mayor número de situaciones y condiciones meteorológicas, como episodios de lluvia o variaciones estacionales. Esta ampliación permitiría mejorar la representatividad del conjunto de datos y reforzar la capacidad de generalización del modelo desarrollado.

En cuanto al análisis predictivo, el proyecto ya cuenta con un modelo de aprendizaje automático capaz de estimar el nivel de tráfico a partir de variables temporales y meteorológicas. Como línea de mejora, se contempla optimizar dicho modelo mediante la incorporación de nuevos datos y el ajuste de sus parámetros, especialmente para mejorar la detección de situaciones de tráfico elevado.

Asimismo, se prevé el desarrollo de una interfaz de visualización sencilla que facilite la consulta de los resultados obtenidos. Esta herramienta permitiría analizar de forma más intuitiva las predicciones del modelo y comparar el comportamiento del tráfico según franjas horarias o condiciones climáticas, sin necesidad de acceder directamente al dataset o al entorno de modelado.

De este modo, TrafiVison evolucionaría desde un sistema de recopilación y análisis de datos hacia una herramienta más accesible y orientada a la interpretación práctica de la información, manteniendo un alcance realista y acorde a los objetivos del proyecto.

## Capítulo 4. PROPUESTA DE SOLUCIÓN (DISEÑO)

En este capítulo se describe la propuesta de solución adoptada para abordar el problema del análisis y la predicción del tráfico urbano en la ciudad de Madrid. Se detalla cómo se ha diseñado el sistema desde un punto de vista técnico y funcional, explicando la arquitectura general, la división del problema en componentes independientes y las tecnologías empleadas en cada fase del proceso.

La solución planteada se basa en una arquitectura modular que permite automatizar de extremo a extremo el flujo de datos, desde su obtención hasta su análisis. Este enfoque facilita la escalabilidad del sistema, el mantenimiento del código y la incorporación progresiva de nuevas funcionalidades sin alterar el núcleo del proyecto.

El diseño del sistema se apoya en un proceso ETL (Extracción, Transformación y Carga) como eje central de la arquitectura. A partir de este proceso, se construye un dataset propio y coherente que sirve como base para el análisis exploratorio y el posterior modelado predictivo del tráfico. Sobre esta base de datos estructurada se añade una capa de análisis mediante técnicas de aprendizaje automático, orientada a clasificar y estimar niveles de tráfico en función de variables temporales y meteorológicas.

Desde el punto de vista tecnológico, la solución combina scripts desarrollados en Python para la automatización del proceso ETL con herramientas de análisis y modelado que permiten validar distintos enfoques de aprendizaje automático. Esta separación entre la fase de generación del dato y la fase de experimentación facilita la validación de modelos y la toma de decisiones fundamentadas sobre qué técnicas resultan más adecuadas para el problema planteado.

El diseño propuesto no se limita únicamente a la recolección de datos, sino que establece una base sólida para la evolución del sistema hacia escenarios más avanzados, como la predicción del tráfico y su visualización mediante interfaces interactivas. De este modo, TrafiVisión se concibe como una solución

integral que conecta datos abiertos, visión por computador y técnicas de análisis avanzado dentro de una arquitectura coherente y reproducible.

## 4.1 Organización de las subtarefas

El diseño del proyecto TrafiVisión se centra en la creación de una arquitectura modular orientada a automatizar la captura, limpieza y análisis de datos de tráfico en la ciudad de Madrid.

La solución se apoya en un proceso ETL (Extracción, Transformación y Carga) completamente automatizado, sobre el que se ha comenzado a trabajar una capa de modelado predictivo y que servirá como base para futuras visualizaciones analíticas.

El sistema se divide en tres grandes módulos:

- Extracción automática de datos (E): obtención de imágenes de tráfico y datos meteorológicos.
- Transformación y limpieza (T): depuración, estandarización y unificación de los datos en un único dataset.
- Carga y análisis (L): almacenamiento del dataset final y preparación para el análisis y el modelado predictivo.

Cada módulo se implementa mediante scripts desarrollados en Python, integrando librerías como requests, pandas, schedule, ultralytics y os, junto con una estructura de carpetas organizada para almacenar tanto las imágenes como los archivos CSV generados en cada fase.

### Arquitectura general

El proyecto se ejecuta sobre una arquitectura software completamente local, organizada en tres niveles:

- Nivel de datos: recopilación automática de información desde fuentes abiertas del Ayuntamiento de Madrid (cámaras de tráfico) y la API Open-Meteo.
- Nivel de procesamiento: scripts en Python encargados de limpiar, integrar y transformar los datos.
- Nivel de análisis: uso de herramientas de inteligencia artificial, como Altair AI Studio, para experimentar con modelos predictivos de tráfico.

No se requiere hardware adicional más allá del equipo de desarrollo. No obstante, la arquitectura propuesta es fácilmente escalable y podría adaptarse a entornos en la nube o servidores externos si fuese necesario.

## Organización de subtareas

### Subtarea 1: Selección y análisis de fuentes de datos

#### Descripción

Se seleccionaron fuentes de información públicas y actualizables en tiempo real, priorizando su fiabilidad, accesibilidad y formato estructurado. Las fuentes elegidas fueron:

- Cámaras de tráfico del Ayuntamiento de Madrid, que proporcionan imágenes en formato JPG actualizadas periódicamente.
- API de Open-Meteo, que ofrece datos meteorológicos en formato JSON, incluyendo temperatura y precipitaciones.

#### Recursos

Librerías: requests, os, datetime

Formatos: .jpg (imágenes) y .json (datos meteorológicos)

### **Motivo de elección**

Ambas fuentes son abiertas, estables y presentan una estructura regular que facilita su integración en procesos automatizados.

## **Subtarea 2: Descarga y almacenamiento de imágenes**

### **Descripción**

Mediante el script `etl_camaras_madrid.py` se implementó un proceso automatizado que descarga imágenes de diez cámaras seleccionadas en puntos clave de Madrid (Alcalá, Cibeles, Plaza Castilla, Gran Vía, entre otros) con una frecuencia de 15 minutos.

Cada imagen se almacena localmente incluyendo en su nombre la ubicación, la fecha y la hora de captura.

### **Entrada**

URLs de las cámaras seleccionadas.

### **Salida**

Imágenes almacenadas localmente con nombre estructurado (calle\_fecha\_hora.jpg).

### **Recursos**

Librerías: requests, os, datetime

Carpeta destino: `imagenesTrafico`

### **Comentarios**

Durante las primeras pruebas se detectaron errores de conexión puntuales en algunas cámaras, lo que permitió ajustar el proceso para mejorar su estabilidad.

## **Subtarea 3: Obtención de datos meteorológicos**

### **Descripción**

Se desarrolló el script `etl_tiempo.py`, encargado de consultar la API de Open-Meteo para obtener datos meteorológicos en tiempo real.

El proceso se sincroniza con la captura de imágenes, ejecutándose cada 15 minutos y almacenando los resultados en un archivo CSV.

### **Entrada**

Coordenadas geográficas de Madrid (40.4168, -3.7038).

### **Salida**

Archivo `tiempo_madrid.csv` con columnas de fecha, hora, temperatura, lluvia y litros por metro cuadrado.

### **Recursos**

Librerías: requests, pandas, schedule

Carpeta destino: `csv`

### **Incidencias**

Inicialmente se detectó un formato incorrecto en la hora (fecha "1900-01-01"), que fue corregido posteriormente en la fase de limpieza.

## **Subtarea 4: Análisis de imágenes mediante YOLOv8**

### **Descripción**

En esta fase se aplicó el modelo YOLOv8, a través de la librería ultralytics, para analizar cada imagen descargada y detectar vehículos.

El script `yolo_final.py` procesa las imágenes y genera un CSV con el número de vehículos detectados y una clasificación del nivel de tráfico (bajo, medio o elevado).

### **Entrada**

Carpeta `imagenesTrafico`.

### **Salida**

Archivo `yolo_final.csv` con columnas de imagen, número de vehículos y nivel de tráfico.

### **Recursos**

Librerías: ultralytics, pandas, os

Modelo: yolov8n.pt (versión ligera optimizada para ejecución local)

### **Resultados**

Se generaron etiquetas automáticas para aproximadamente 3.000 imágenes, constituyendo la base principal del dataset final.



## Subtarea 5: Limpieza, integración y generación del dataset final

### Descripción

Se integraron los archivos generados en las fases anteriores mediante el script `merge_datasets_final.py`.

Durante este proceso se corrigieron formatos, se eliminaron inconsistencias y se añadieron variables derivadas como:

- Día laborable / no laborable
- Franja horaria (madrugada, mañana, mediodía, tarde, noche)

### Entrada

Archivos CSV generados en las fases previas.

### Salida

Archivo `dataset_final_limpio.csv`.

### Recursos

Librerías: pandas, datetime, os

Carpeta destino: `csv`

### Comentarios

Se detectaron pequeños desfases temporales entre los datos de cámaras y clima, que se resolvieron mediante una coincidencia por rangos horarios.

## Subtarea 6: Preparación para el modelado

### Descripción

Con el dataset limpio y estructurado, se preparó la base para la fase de modelado predictivo.

El archivo final se conectó con Altair AI Studio para experimentar con distintos algoritmos de clasificación, evaluando su rendimiento mediante validación cruzada.

## **Entrada**

`dataset_final_limpio.csv`

## **Resultado**

Evaluación comparativa de varios modelos, seleccionando el árbol de decisión como el enfoque más equilibrado en términos de precisión e interpretabilidad.

## **Subtarea 7: Versionado y documentación**

### **Descripción**

Todo el proyecto se ha versionado en un repositorio público de GitHub, lo que permite mantener trazabilidad del desarrollo, control de cambios y una organización clara del código, los datasets y la documentación.

### **Recursos**

Herramientas: Git y GitHub

Contenido: scripts ETL, datasets, experimentos de modelado y documentación del proyecto.

## Capítulo 5. DESARROLLO / IMPLEMENTACIÓN

En este capítulo se describe la implementación real del sistema TrafiVison, diferenciando entre las funcionalidades que ya se encuentran desarrolladas y aquellas que se prevé completar antes de la entrega final del proyecto.

### Implementación realizada

En la fase actual, el proyecto cuenta con una implementación funcional del proceso ETL que permite trabajar con datos reales de tráfico y clima de forma automatizada.

Se ha desarrollado un sistema de extracción automática que recopila imágenes de diez cámaras públicas del Ayuntamiento de Madrid cada 15 minutos, almacenándolas de forma estructurada junto con su fecha, hora y ubicación. De manera paralela, se obtienen datos meteorológicos mediante la API Open-Meteo, registrando variables como temperatura, precipitación y tipo de lluvia para la ciudad de Madrid.

Sobre las imágenes capturadas, se ha integrado un módulo de visión por computador basado en YOLOv8, que permite detectar vehículos y estimar el nivel de tráfico. Este análisis genera etiquetas automáticas que clasifican cada captura en niveles de tráfico bajo, medio o elevado.

Posteriormente, se ha implementado una fase de transformación y limpieza de datos en la que se corrigen errores de formato, se sincronizan las distintas fuentes y se generan variables derivadas como franja horaria o tipo de día (laborable o no laborable). El resultado de este proceso es un dataset unificado y limpio en formato CSV, que constituye la base de datos principal del proyecto.

Con este dataset, se ha iniciado una fase de experimentación con modelos de aprendizaje automático utilizando la herramienta Altair AI Studio. En esta etapa se han probado distintos algoritmos de clasificación con el objetivo de evaluar la viabilidad de la predicción del nivel de tráfico. Los experimentos realizados muestran que los modelos basados en árboles de decisión ofrecen un

rendimiento adecuado para el volumen de datos disponible, alcanzando precisiones en torno al 73%.

Esta fase permite validar que el dataset generado es coherente y apto para tareas de modelado predictivo.

## **Implementación prevista hasta el final del proyecto**

De cara a la fase final del proyecto, se prevé completar y consolidar las siguientes tareas:

- Continuar la recolección de datos para aumentar el número de muestras y mejorar la representación de distintas condiciones meteorológicas y franjas horarias.
- Seleccionar y fijar un modelo predictivo definitivo a partir de los experimentos realizados en Altair AI Studio.
- Exportar el modelo entrenado a un entorno Python, de forma que pueda ser reutilizado fuera de la herramienta visual.
- Desarrollar una interfaz sencilla que permita introducir variables como hora, temperatura, lluvia y tipo de día, y obtener como salida una estimación del nivel de tráfico.
- Incorporar visualizaciones básicas que faciliten la interpretación de los resultados y el análisis de patrones de congestión.

Estas tareas se apoyarán en la infraestructura ya implementada, sin modificar la arquitectura general del sistema, y permitirán cerrar el proyecto con una solución completa que integre datos reales, análisis automatizado y predicción del tráfico urbano.

# Capítulo 6. Modelado

## Modelado

### Estado actual del modelado

En la fase actual del proyecto TrafiVisión, el trabajo se ha centrado en la preparación, validación y utilización del dataset base como punto de partida para el modelado predictivo del tráfico urbano.

A día de hoy, el proyecto cuenta con un conjunto de datos completamente integrado y depurado, construido de forma automatizada a partir de tres fuentes principales:

- Imágenes de tráfico obtenidas en tiempo real desde diez cámaras públicas del Ayuntamiento de Madrid.
- Datos meteorológicos proporcionados por la API Open-Meteo, que incluyen variables como temperatura, precipitación y tipo de lluvia.
- Etiquetas de tráfico generadas automáticamente mediante el modelo de visión por computador YOLOv8, que clasifica cada imagen en niveles de tráfico bajo, medio o elevado en función del número de vehículos detectados.

El resultado de este proceso es el archivo `dataset_final_limpio.csv`, un conjunto de datos estructurado, coherente y preparado para su uso en tareas de análisis y aprendizaje automático.

Cada registro del dataset combina información temporal, climática y de localización, junto con variables derivadas que enriquecen el análisis, entre las que se incluyen:

- Tipo de día (laborable o no laborable).

- Franja horaria (madrugada, mañana, mediodía, tarde o noche).
- Nivel de tráfico estimado.

Este dataset constituye la base fundamental sobre la que se ha iniciado la fase de experimentación con modelos de clasificación, permitiendo evaluar la viabilidad de la predicción del nivel de tráfico a partir de variables temporales y meteorológicas.

## Objetivo del modelado

El objetivo principal del modelado en TrafiVision es **predecir el nivel de tráfico** a partir de variables meteorológicas, temporales y contextuales presentes en el dataset generado.

El modelo busca identificar patrones de congestión urbana y estimar la intensidad del tráfico en distintas zonas de Madrid en función de factores como la franja horaria, la temperatura, la presencia de lluvia y el tipo de día (laborable o no laborable).

Este modelado permite validar que el conjunto de datos construido contiene información relevante para la predicción del tráfico y sienta las bases para futuras aplicaciones, como sistemas de apoyo a la toma de decisiones o herramientas de visualización que faciliten el análisis de la movilidad urbana.

## Herramientas de modelado

Para la creación y evaluación de los modelos predictivos se han empleado plataformas de inteligencia artificial visuales que permiten trabajar directamente con conjuntos de datos en formato CSV sin necesidad de desarrollar código adicional.

En concreto, el modelado se ha realizado utilizando **Altair AI Studio (RapidMiner)**, que ofrece un entorno gráfico para diseñar flujos de trabajo de aprendizaje automático, entrenar modelos, validarlos y comparar su rendimiento de forma estructurada.

Esta herramienta ha permitido:

- Conectar directamente el dataset generado (dataset\_final\_limpio.csv).
- Definir las variables de entrada y la variable objetivo (nivel de tráfico).
- Probar distintos algoritmos de clasificación.
- Evaluar los resultados mediante validación cruzada y métricas de rendimiento.

El uso de una plataforma visual facilita la comprensión del proceso de modelado y la comparación entre algoritmos, además de servir como base para una futura integración del modelo en aplicaciones externas o interfaces de visualización.

## Fases del proceso de modelado

### 1. Preparación del dataset

En primer lugar, se realizó la verificación del formato y la consistencia del archivo dataset\_final\_limpio.csv, comprobando que no existieran valores nulos, errores de formato ni incoherencias temporales.

El dataset fue cargado directamente en la plataforma Altair AI Studio, donde se seleccionaron únicamente las variables relevantes para el proceso de modelado.

Para la evaluación de los modelos no se utilizó una simple división entrenamiento/prueba, sino un esquema de **validación cruzada (Cross Validation)** con 10 particiones, lo que permite obtener resultados más robustos

y reducir el riesgo de sobreajuste, especialmente teniendo en cuenta el tamaño limitado del conjunto de datos.

## 2. Selección de variables

A partir del dataset final, se definieron como variables de entrada aquellas relacionadas con el contexto temporal y meteorológico:

- Temperatura
- Lluvia (litros/m<sup>2</sup>)
- Hora
- Franja horaria
- Tipo de día (laborable / no laborable)
- Calle (ubicación de la cámara)

Como variable objetivo se estableció el campo **nivel\_trafico**, que clasifica cada registro en tráfico bajo, medio o elevado.

Esta selección permite analizar la influencia combinada del clima, el tiempo y la localización sobre la intensidad del tráfico.

## 3. Entrenamiento de modelos

Durante la fase de modelado se entrenaron y compararon distintos algoritmos de clasificación supervisada disponibles en Altair AI Studio, utilizando el mismo esquema de validación cruzada para todos ellos. Los modelos evaluados fueron:

- Árbol de decisión (Decision Tree)
- Random Forest



- Gradient Boosted Trees
- Naive Bayes
- k-Nearest Neighbors (k-NN)



Cada modelo fue entrenado automáticamente sobre las particiones definidas en la validación cruzada, manteniendo las mismas variables de entrada y la misma variable objetivo, con el fin de realizar una comparación justa entre algoritmos.



#### **4. Evaluación y validación**

El rendimiento de los modelos se evaluó principalmente mediante la métrica de **accuracy**, acompañada del análisis de la matriz de confusión, que permite observar el comportamiento del modelo en cada una de las clases (bajo, medio y elevado).

Los resultados obtenidos muestran que el **árbol de decisión** es el modelo que ofrece un mejor equilibrio entre simplicidad, interpretabilidad y rendimiento, alcanzando una precisión aproximada del **73%**, ligeramente superior al resto de algoritmos probados.

Este modelo se selecciona como referencia para el proyecto, teniendo en cuenta que el tamaño del dataset es todavía reducido (alrededor de 3.000 registros) y que un mayor volumen de datos en distintas condiciones permitiría mejorar la capacidad predictiva en el futuro.





## Resultados esperados

En el estado actual del proyecto, se espera que el modelo predictivo sea capaz de **identificar el nivel de tráfico de forma consistente** a partir de

variables temporales y meteorológicas, como la hora del día, la franja horaria, la temperatura y la presencia de lluvia. Los resultados obtenidos durante la fase de experimentación muestran que el modelo alcanza una precisión cercana al 73%, lo que se considera adecuado teniendo en cuenta el volumen y la distribución del dataset disponible.

A corto plazo, el objetivo es **consolidar y estabilizar el rendimiento del modelo**, asegurando su correcta generalización dentro de las clases de tráfico bajo, medio y elevado. A medio plazo, se plantea la ampliación del conjunto de datos con nuevas capturas que permitan mejorar la representación de situaciones menos frecuentes, lo que contribuiría a incrementar la precisión y fiabilidad de las predicciones.

Una vez validado y optimizado, el modelo podrá integrarse dentro del pipeline de TrafiVision, de manera que los nuevos lotes de datos procesados —imágenes y condiciones meteorológicas— puedan utilizarse tanto para alimentar el sistema de predicción como para reentrenar el modelo de forma periódica.

## Limitaciones del modelo

El modelo predictivo desarrollado presenta una serie de limitaciones que deben tenerse en cuenta a la hora de interpretar los resultados obtenidos. Estas limitaciones están directamente relacionadas con las características del conjunto de datos disponible y con el alcance temporal del proyecto.

En primer lugar, el tamaño del dataset es relativamente reducido, con aproximadamente 3.000 registros. Aunque este volumen ha sido suficiente para validar la viabilidad del enfoque predictivo y obtener resultados coherentes, limita la capacidad del modelo para generalizar ante situaciones poco frecuentes o atípicas.

Asimismo, el conjunto de datos se ha generado durante un periodo de tiempo acotado, lo que implica que no se han podido recoger muestras representativas de distintas épocas del año. En consecuencia, el modelo no ha sido expuesto a variaciones estacionales más amplias, como cambios significativos de temperatura, patrones de tráfico propios de vacaciones o eventos puntuales.

Otra limitación relevante es el desbalance entre las clases de tráfico. La mayoría de los registros corresponden a situaciones de tráfico bajo o medio, mientras que los casos de tráfico elevado son menos frecuentes. Este desequilibrio afecta especialmente a la precisión del modelo a la hora de identificar escenarios de alta congestión.

Por último, la calidad de las predicciones depende en gran medida de la precisión de la detección visual realizada por el modelo YOLOv8. En condiciones de baja iluminación o presencia de reflejos, especialmente durante la noche, la detección de vehículos puede verse afectada, lo que repercute indirectamente en el rendimiento del modelo predictivo.

Estas limitaciones no invalidan los resultados obtenidos, pero sí ponen de manifiesto la necesidad de ampliar el conjunto de datos y extender el periodo de observación para mejorar la robustez y la fiabilidad del sistema en futuras iteraciones.

## **Separación entre fase experimental y fase de despliegue**

El proceso de modelado desarrollado en TrafiVision se ha planteado siguiendo una separación clara entre la fase de experimentación y la fase de integración o despliegue del modelo, tal y como se realiza habitualmente en proyectos reales de análisis de datos.

Durante la fase experimental, se ha utilizado Altair AI Studio como entorno de trabajo para el entrenamiento, validación y comparación de distintos algoritmos de clasificación. Esta herramienta ha permitido evaluar de forma ágil el comportamiento de los modelos, analizar métricas de rendimiento y seleccionar el enfoque más adecuado sin necesidad de implementar código específico. En este contexto, Altair se emplea como un laboratorio de experimentación orientado a la toma de decisiones técnicas.

Una vez identificado el modelo más adecuado —en este caso, el árbol de decisión—, la fase de despliegue se plantea en un entorno Python independiente. Esta separación responde a criterios de flexibilidad y reutilización, ya que Python permite integrar el modelo dentro de aplicaciones externas, automatizar su uso y conectarlo con interfaces gráficas o sistemas de visualización.

En este enfoque, Altair AI Studio se utiliza para validar el modelo y justificar su elección, mientras que Python se concibe como el entorno final para la implementación funcional del sistema predictivo. De este modo, el modelo entrenado puede replicarse utilizando las mismas variables y lógica de decisión, permitiendo su uso en una aplicación interactiva donde el usuario introduzca condiciones como la hora, el clima o la ubicación y obtenga una estimación del nivel de tráfico.

Esta separación entre experimentación y despliegue aporta claridad al diseño del sistema, facilita su mantenimiento y sienta las bases para una futura evolución del proyecto hacia un entorno más operativo y orientado a usuario final.

## **Perspectiva futura**

Como evolución natural del trabajo realizado, en fases posteriores del proyecto se contempla la integración del modelo predictivo en un entorno más orientado a su uso práctico. En este sentido, el proceso de modelado desarrollado hasta el momento se ha planteado como una fase de experimentación y validación, mientras que la integración funcional del modelo se abordará en un entorno independiente.

Durante el desarrollo actual, Altair AI Studio se ha utilizado como herramienta de experimentación, permitiendo entrenar, validar y comparar distintos algoritmos de clasificación sobre el dataset generado. Este enfoque ha facilitado la selección del modelo más adecuado en función de su rendimiento y comportamiento, actuando como un entorno de análisis previo a la fase de despliegue.

De cara a la fase final del proyecto, se prevé replicar el modelo seleccionado en un entorno Python, con el objetivo de integrarlo dentro de una aplicación

sencilla de consulta. Esta aplicación permitiría introducir variables como la hora del día, la franja horaria, la temperatura, la presencia de lluvia o el tipo de día, y obtener como resultado una estimación del nivel de tráfico. De este modo, se simularía un escenario de uso real en el que el sistema actúe como apoyo al análisis y la comprensión del tráfico urbano.

Asimismo, a medida que se amplíe el conjunto de datos con nuevas capturas en distintas condiciones meteorológicas y temporales, el modelo podría reentrenarse periódicamente para mejorar su precisión y su capacidad de generalización, manteniendo la coherencia con la arquitectura ya implementada.

En conjunto, la fase de modelado representa un punto de transición en TrafiVision, permitiendo evolucionar desde un sistema centrado en la recopilación y preparación de datos hacia una herramienta analítica con capacidad predictiva, orientada al estudio de los patrones reales de movilidad urbana en la ciudad de Madrid.

## **Conclusión del modelado**

La fase de modelado desarrollada en el proyecto TrafiVision ha permitido validar la viabilidad de aplicar técnicas de aprendizaje automático para la predicción del nivel de tráfico urbano a partir de datos reales de carácter temporal, meteorológico y contextual.

A partir del dataset generado mediante el proceso ETL, se ha llevado a cabo una fase de experimentación utilizando Altair AI Studio, en la que se han evaluado distintos algoritmos de clasificación supervisada. Los resultados obtenidos muestran que el conjunto de variables seleccionadas contiene información relevante para estimar el nivel de tráfico, alcanzándose una precisión cercana al 73% con el modelo de árbol de decisión, considerado adecuado para el volumen y las características actuales del conjunto de datos.

El modelado ha puesto de manifiesto tanto el potencial del enfoque propuesto como sus limitaciones, especialmente en relación con el tamaño del dataset, el desbalance entre clases y la ausencia de datos representativos de distintas épocas del año. No obstante, estos factores no invalidan los resultados

obtenidos, sino que delimitan claramente el contexto en el que el modelo es aplicable en su estado actual.

En conjunto, esta fase de modelado cumple su objetivo principal: demostrar que los datos recopilados y procesados por TrafiVision permiten construir un modelo predictivo coherente y funcional, sentando una base sólida para futuras mejoras, ampliaciones del dataset e integración del modelo en aplicaciones orientadas a la visualización y al apoyo en la toma de decisiones sobre movilidad urbana.



## Capítulo 7. BIBLIOGRAFIA/WEBGRAFIA

### Fuentes técnicas y documentación

[1] Open-Meteo. *API Documentation: Free Weather Forecast API for Developers*. Disponible en: <https://open-meteo.com/>  
Consultado en octubre de 2025.

[2] Ayuntamiento de Madrid. *Portal de Datos Abiertos: Tráfico en tiempo real y cámaras urbanas*. Disponible en:  
<https://informo.madrid.es/informo/tmadrid/camaras.jsp>  
Consultado en octubre de 2025.

[3] Ultralytics. *YOLOv8 Documentation — Object Detection Models*. Disponible en:  
<https://docs.ultralytics.com/>  
Consultado en noviembre de 2025.

[4] Python Software Foundation. *Python 3.9 Documentation*. Disponible en:  
<https://docs.python.org/3.9/>

[5] Pandas Development Team. *Pandas User Guide — Data Analysis Library*. Disponible en:  
<https://pandas.pydata.org/docs/>

[6] Schedule Library. *Python Job Scheduling for Humans*. Disponible en:  
<https://schedule.readthedocs.io/>

[7] Requests Library. *Python HTTP for Humans*. Disponible en:  
<https://requests.readthedocs.io/>

[8] Azure Machine Learning Studio (Alair). *Documentación de Azure Machine Learning*. Disponible en:  
<https://learn.microsoft.com/es-es/azure/machine-learning/>

[9] Google AI Studio. *Herramienta de experimentación en IA*. Disponible en:  
<https://aistudio.google.com/>

### Fuentes académicas y metodológicas

[10] AENOR. AEN/CTN 157 — *Proyectos. Normas y Publicaciones*. [En línea] 2010. Disponible en:

<http://www.aenor.es/aenor/normas/ctn/fichactn.asp?codigonorm=AEN/CTN%20157>

[11] UNE 157001. *Criterios generales para la elaboración de proyectos*. Escuela Universitaria de Ingeniería de Vitoria. 2002.

[12] Universidad Europea de Madrid. *Guía de estilo y normativa para la redacción de proyectos de ingeniería*.

Disponible en:

<http://biblioteca.uem.es/es/aprendizaje-y-formacion/citas-bibliograficas-documentos>

### **Fuentes académicas y de aprendizaje automático**

[13] Hastie, T., Tibshirani, R., Friedman, J. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, 2009.

Referencia clásica sobre modelos de clasificación y validación en aprendizaje automático.

[14] Géron, A. *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow*. O'Reilly Media, 2022.

Manual práctico sobre modelado predictivo, validación cruzada y despliegue de modelos.

[15] Scikit-learn Developers. *Model evaluation: cross-validation and metrics*.

Disponible en: [https://scikit-learn.org/stable/modules/model\\_evaluation.html](https://scikit-learn.org/stable/modules/model_evaluation.html)

Consultado en noviembre de 2025.

## Capítulo 8. ANEXOS

### ANEXO I – Criterios de clasificación y variables derivadas

Durante la fase de diseño del dataset, se establecieron una serie de criterios lógicos para convertir los datos numéricos y contextuales en variables categóricas útiles para el análisis y el futuro modelado predictivo.

Estas reglas fueron implementadas directamente dentro de los scripts de transformación y limpieza, y se aplican de forma automática a cada nuevo registro obtenido por el sistema ETL.

#### 1. Clasificación del nivel de tráfico

El nivel de tráfico se determinó en función del **número de vehículos detectados por el modelo YOLOv8** en cada imagen capturada.

Para convertir este valor numérico en una categoría descriptiva, se establecieron los siguientes rangos:

| Nº de vehículos detectados | Nivel de tráfico asignado |
|----------------------------|---------------------------|
| 0 – 5                      | Bajo                      |
| 6 – 15                     | Medio                     |
| > 15                       | Alto                      |

Estos umbrales se definieron tras observar los resultados iniciales del modelo y su correspondencia visual con las imágenes de las cámaras.

El criterio busca un equilibrio entre la densidad visual y la legibilidad analítica del dataset, facilitando su uso en modelos de clasificación supervisada.

## 2. Clasificación del tipo de lluvia

La variable “lluvia” procede del valor de **precipitación en litros/m<sup>2</sup>** proporcionado por la API de *Open-Meteo*.

Dado que pequeñas cantidades no representan necesariamente lluvia perceptible, se definieron los siguientes intervalos para su categorización:

| <b>Precipitación<br/>(L/m<sup>2</sup>)</b> | <b>Clasificación</b> |
|--------------------------------------------|----------------------|
| ≤ 0.1                                      | No llueve            |
| 0.1 – 0.3                                  | Lluvia débil         |
| > 0.3                                      | Lluvia<br>intensa    |

Estos valores permiten distinguir entre condiciones secas, lloviznas leves y precipitaciones significativas, las cuales influyen directamente en la variación del tráfico urbano.

## 3. Categorización por franja horaria

Cada registro del dataset incluye la hora exacta de captura, la cual se transformó en una **franja horaria** representativa del momento del día.

Esta variable es relevante porque el flujo de tráfico varía de forma predecible según la hora.

Las franjas establecidas fueron:

| <b>Franja horaria</b> | <b>Rango horario<br/>(hh:mm)</b> | <b>Descripción</b>                        |
|-----------------------|----------------------------------|-------------------------------------------|
| Madrugada             | 05:00 – 07:59                    | Tráfico bajo, desplazamientos esenciales. |

|          |               |                                                   |
|----------|---------------|---------------------------------------------------|
| Mañana   | 08:00 – 12:59 | Horas punta laborales, mayor densidad de tráfico. |
| Mediodía | 13:00 – 16:59 | Actividad intermedia, pausas laborales y comidas. |
| Tarde    | 17:00 – 20:59 | Segunda hora punta de retorno a casa.             |
| Noche    | 21:00 – 04:59 | Menor circulación y tráfico reducido.             |

Este formato permite que los algoritmos de predicción puedan relacionar patrones de tráfico con momentos específicos del día, manteniendo la coherencia temporal en todos los registros.

#### 4. Clasificación de días laborables y no laborables

Para mejorar la capacidad predictiva del modelo, se añadió una variable binaria que distingue entre **días laborables y no laborables**, basada en el calendario oficial de la Comunidad de Madrid.

| Tipo de día  | Criterio                                |
|--------------|-----------------------------------------|
| Laborable    | Lunes a viernes (excepto festivos).     |
| No laborable | Sábados, domingos y festivos oficiales. |

Esta variable permite detectar diferencias de comportamiento entre el tráfico diario y el de fines de semana o días festivos, que suelen mostrar patrones menos congestionados.

## **5. Tratamiento de variables categóricas para el modelado**

Las variables categóricas generadas durante la fase de transformación (calle, franja horaria, tipo de día y clasificación de lluvia) fueron diseñadas con el objetivo de facilitar su uso posterior en modelos de aprendizaje automático.

Estas variables permiten representar información contextual compleja de forma estructurada y comprensible, evitando el uso exclusivo de valores numéricos que pueden resultar menos interpretables. Durante la fase de modelado, dichas variables se emplean como atributos de entrada, siendo tratadas internamente por las herramientas de aprendizaje automático mediante técnicas de codificación adecuadas.

La inclusión de estas variables categóricas permite que los modelos aprendan relaciones entre contexto temporal, condiciones meteorológicas y ubicación, contribuyendo a una mejor interpretación de los patrones de tráfico urbano y a una mayor estabilidad del proceso de entrenamiento.

## **Resumen**

Los criterios de clasificación y las variables derivadas definidos en este anexo permiten transformar datos brutos procedentes de distintas fuentes en información estructurada, coherente y semánticamente interpretable. La categorización del nivel de tráfico, la clasificación de la lluvia, la segmentación por franjas horarias y la distinción entre días laborables y no laborables aportan contexto al dataset y facilitan la identificación de patrones relevantes.

Asimismo, el tratamiento de las variables categóricas se ha diseñado pensando en su uso directo en modelos de aprendizaje automático, garantizando que el dataset generado por TrafiVision sea fácilmente escalable, reutilizable y adecuado tanto para análisis exploratorios como para tareas de modelado predictivo. En conjunto, este enfoque refuerza la calidad del dataset y su utilidad como base para el análisis del tráfico urbano.

