



**Universidad
Europea**

UNIVERSIDAD EUROPEA DE MADRID

ESCUELA DE ARQUITECTURA, INGENIERÍA Y DISEÑO

GRADO EN INGENIERIA INFORMÁTICA

PROYECTO COMPUTACIÓN I

TrafiVision

Grupo 5

Anyi Lin

Rodrigo DÍAZ MARTÍNEZ

Dirigido por

MIQUEL COLOBRAN HUGUET

CURSO 2025-2026

TÍTULO: TrafiVisión

AUTOR: Anyi Lin,Rodrigo DÍAZ MARTÍNEZ

TITULACIÓN: GRADO EN INGENIERÍA INFORMÁTICA

DIRECTOR/ES DEL PROYECTO: MIQUEL COLOBRAN HUGUET

FECHA: Enero 2026

REPOSITORIO: <https://github.com/RodrigoVII/TrafiVison>

RESUMEN

El proyecto TrafiVisión aborda el problema del análisis y la predicción del tráfico urbano en la ciudad de Madrid a partir de datos reales procedentes de fuentes abiertas. La gestión eficiente del tráfico es un reto clave en entornos urbanos, especialmente en el contexto de las Smart Cities, donde resulta necesario disponer de herramientas que permitan analizar patrones de movilidad y anticipar situaciones de congestión.

Para dar respuesta a este problema, se ha diseñado e implementado un sistema automatizado basado en un proceso ETL (Extracción, Transformación y Carga) que integra información visual procedente de cámaras públicas de tráfico del Ayuntamiento de Madrid con datos meteorológicos obtenidos a través de la API Open-Meteo. Sobre las imágenes recopiladas se ha aplicado un modelo de visión por computador basado en YOLOv8, encargado de detectar vehículos y clasificar el nivel de tráfico en categorías bajo, medio y alto. El resultado es un dataset propio, limpio y estructurado, preparado para su análisis y modelado.

A partir de este conjunto de datos se ha desarrollado un modelo de aprendizaje automático para la predicción del nivel de tráfico, evaluando distintos algoritmos de clasificación y seleccionando aquellos con mejor equilibrio entre rendimiento e interpretabilidad. El modelo resultante ha sido integrado en una aplicación gráfica desarrollada en Python, que permite realizar predicciones de forma interactiva en función de variables temporales, espaciales y meteorológicas.

Como conclusión, el proyecto demuestra la viabilidad de combinar datos abiertos, visión por computador y aprendizaje automático para el análisis y la predicción del tráfico urbano, sentando una base sólida para futuras ampliaciones y aplicaciones prácticas en el ámbito de la movilidad inteligente.

Palabras clave: tráfico urbano, Smart City, visión por computador, aprendizaje automático, proceso ETL, datos abiertos.

ABSTRACT

The TrafiVisión project addresses the problem of urban traffic analysis and prediction in the city of Madrid using real data obtained from open and official sources. Efficient traffic management is a key challenge in modern urban environments, especially within the context of Smart Cities, where data-driven tools are required to analyze mobility patterns and anticipate congestion situations.

To tackle this problem, an automated system based on an ETL (Extract, Transform and Load) process has been designed and implemented. This system integrates visual information captured from public traffic cameras provided by the Madrid City Council with meteorological data obtained through the Open-Meteo API. A computer vision model based on YOLOv8 is applied to the captured images to detect vehicles and classify traffic levels into low, medium and high categories. The result is a clean, structured and consistent dataset suitable for analysis and predictive modeling.

Using this dataset, several supervised machine learning models were evaluated to predict traffic levels based on temporal, spatial and meteorological variables. Tree-based models showed the best balance between performance and interpretability. The selected model was subsequently integrated into a graphical application developed in Python, allowing users to interactively input conditions and obtain traffic level predictions.

In conclusion, the project demonstrates the feasibility of combining open data, computer vision and machine learning techniques to analyze and predict urban traffic, providing a solid foundation for future extensions and practical applications in intelligent mobility systems.

Keywords: urban traffic, Smart City, computer vision, machine learning, ETL process, open data.

INDICE

RESUMEN.....	3
ABSTRACT.....	4
Capítulo 1. INTRODUCCIÓN.....	6
1.1 Estado del arte.....	7
1.2 Contexto y justificación.....	8
1.3 Objetivos generales.....	9
1.4 Objetivos específicos.....	10
1.5 Planificación.....	12
Capítulo 2. TECNOLOGÍAS USADAS.....	13
Capítulo 3. ANALISIS DEL PROBLEMA.....	16
Análisis del problema.....	20
Capítulo 4. PROPUESTA DE SOLUCIÓN (DISEÑO).....	27
4.1 Organización de las subtareass.....	28
Organización de subtareass.....	29
Capítulo 5. DESARROLLO / IMPLEMENTACIÓN.....	36
Capítulo 6. Modelado.....	39
Modelado.....	39
Separación entre fase experimental y fase de despliegue.....	47
Perspectiva futura del modelado.....	48
Conclusión del modelado.....	49
Capítulo 7. BIBLIOGRAFIA/WEBGRAFIA.....	51
Capítulo 8. ANEXOS.....	53
ANEXO I – Criterios de clasificación y variables derivadas.....	53

Capítulo 1. INTRODUCCIÓN

El proyecto **TrafiVison** tiene como objetivo desarrollar un sistema automatizado de recopilación, integración y análisis de datos de tráfico urbano en la ciudad de Madrid. El enfoque adoptado se basa en la implementación de un proceso **ETL (Extracción, Transformación y Carga)** capaz de combinar información visual procedente de cámaras públicas de tráfico con datos meteorológicos obtenidos a través de la plataforma **Open-Meteo**, generando un conjunto de datos estructurado y preparado para su análisis y modelado.

En la fase actual, el sistema es capaz de **extraer imágenes en tiempo real** desde distintas ubicaciones estratégicas de la ciudad, registrar de forma precisa su fecha y hora, y asociar a cada captura las condiciones meteorológicas correspondientes, como la temperatura, la precipitación y el tipo de lluvia. Sobre estas imágenes se aplica un modelo de **visión por computador basado en YOLOv8**, que permite detectar vehículos y clasificar automáticamente el nivel de tráfico en tres categorías: **bajo, medio y elevado**. Toda esta información se consolida en un **dataset unificado y limpio en formato CSV**, que constituye la base del sistema de análisis.

El trabajo realizado se ha centrado en garantizar la **calidad, coherencia temporal y consistencia estructural de los datos**, abordando y corrigiendo incidencias detectadas durante las primeras fases de ejecución, como errores en el formato de la hora o pequeños desfases temporales entre la captura de imágenes y los datos meteorológicos asociados. Este proceso de depuración ha permitido obtener un conjunto de datos fiable y adecuado para su uso en técnicas de aprendizaje automático.

A partir del dataset generado, se ha llevado a cabo una fase de **modelado predictivo**, utilizando algoritmos de clasificación supervisada para estimar el nivel de tráfico en función de variables temporales, espaciales y meteorológicas, tales como la franja horaria, el carácter laborable del día, la ubicación de la cámara o las condiciones climáticas. El proceso de entrenamiento y validación de los modelos se ha realizado mediante la

herramienta **Altair AI Studio**, permitiendo comparar distintos enfoques y seleccionar el modelo con mejor rendimiento global.

Como resultado, el sistema desarrollado demuestra que es posible **predecir el nivel de tráfico urbano** a partir de datos abiertos y procesos automatizados, incluso con un volumen de datos limitado, sentando una base sólida para su ampliación y mejora en entornos reales.

Como fase final del proyecto, se prevé el desarrollo de una **aplicación visual sencilla en Python** que permita interactuar con el modelo predictivo entrenado. Esta herramienta estaría orientada a la consulta del sistema, facilitando la selección de distintos parámetros de entrada —como la calle, la franja horaria, el tipo de día o las condiciones meteorológicas— y mostrando como resultado la **estimación del nivel de tráfico** correspondiente. De este modo, el proyecto no solo aborda el análisis y modelado de datos, sino que avanza hacia una solución práctica y accesible para la toma de decisiones en el ámbito de la movilidad urbana.

1.1 Estado del arte

En los últimos años, diferentes organismos públicos han puesto a disposición de la ciudadanía **datos abiertos sobre movilidad y tráfico urbano**, permitiendo el desarrollo de proyectos que combinan información visual, meteorológica y de sensores para comprender mejor la congestión vial. En el caso de Madrid, el **Ayuntamiento** ofrece un sistema de **cámaras de tráfico en tiempo real**, accesibles de forma pública, y diversas **APIs de datos abiertos** que incluyen información sobre el estado de las vías, incidencias o intensidad de circulación.

Pese a ello, la mayor parte de estos datos se encuentran **dispersos, en formatos heterogéneos y con frecuencias de actualización variables**, lo que dificulta su aprovechamiento conjunto. De manera similar, las fuentes meteorológicas —como las proporcionadas por **Open-Meteo o AEMET**— suelen mantenerse separadas del resto de los sistemas de información de tráfico, reduciendo las posibilidades de correlacionar factores ambientales con los niveles de congestión.

Hasta el momento, la mayoría de proyectos existentes se centran en **visualizar tráfico en tiempo real o mostrar cámaras en mapas interactivos**, pero pocos abordan la **automatización del proceso ETL completo** (Extracción, Transformación y Carga) que permita mantener un **dataset limpio y normalizado** de forma continua. Este tipo de integración es esencial para garantizar la **consistencia temporal y la calidad de los datos** cuando se pretende entrenar modelos de aprendizaje automático.

En este contexto, **TrafiVison** surge como una propuesta práctica y académica que busca **automatizar la recogida y estandarización** de datos de tráfico en Madrid, **fusionando imágenes, información meteorológica y variables temporales** (hora, día de la semana, laborable/festivo). En esta primera fase, el sistema se centra en construir un dataset propio y verificable; en etapas futuras, se prevé extenderlo hacia la **predicción de niveles de tráfico y visualización de patrones de movilidad**.

1.2 Contexto y justificación

El análisis de datos abiertos relacionados con el tráfico se ha convertido en una herramienta esencial para **mejorar la movilidad urbana, reducir la congestión y optimizar la planificación del transporte público y privado**. Sin embargo, la información disponible suele proceder de **fuentes heterogéneas**, con distintos formatos, niveles de actualización y estructuras, lo que **complica su integración y análisis conjunto**.

En este contexto, el proyecto **TrafiVison** nace con el propósito de **unificar y automatizar la recopilación de datos de tráfico y clima en la ciudad de Madrid**, creando un flujo ETL (Extracción, Transformación y Carga) que garantice la coherencia y la trazabilidad de la información. El sistema combina imágenes captadas desde cámaras públicas del Ayuntamiento de Madrid con datos meteorológicos en tiempo real de la API **Open-Meteo**, generando un dataset propio, estructurado y limpio, listo para ser utilizado en futuros análisis.

Desde el punto de vista **académico**, TrafiVison representa un **caso práctico de aplicación de técnicas de ingeniería de datos** dentro del ámbito de la inteligencia artificial y el aprendizaje automático, abordando todas las etapas del ciclo de vida de los datos: obtención, limpieza, integración y validación.

En el plano **social y tecnológico**, el proyecto contribuye al **aprovechamiento de los datos abiertos** como herramienta de conocimiento, fomentando la transparencia y la innovación en la gestión de la movilidad urbana. A largo plazo, TrafiVison busca sentar las bases para el desarrollo de **modelos predictivos** que ayuden a anticipar niveles de tráfico y a diseñar estrategias de movilidad más sostenibles y seguras.

1.3 Objetivos generales

El objetivo principal del proyecto TrafiVison es diseñar e implementar un proceso ETL (Extracción, Transformación y Carga) que integre datos abiertos de tráfico y condiciones meteorológicas para generar un dataset propio, limpio y estructurado, capaz de servir como base para el análisis y la predicción del comportamiento del tráfico urbano en la ciudad de Madrid.

En su estado actual, el proyecto cuenta con un proceso completo de extracción y transformación de datos, en el que se han automatizado los siguientes componentes:

- La descarga periódica de imágenes procedentes de diez cámaras públicas de tráfico del Ayuntamiento de Madrid.
- La recopilación de datos meteorológicos en tiempo real mediante la API Open-Meteo.
- El análisis automatizado de las imágenes capturadas mediante el modelo de visión por computador YOLOv8, que permite detectar vehículos y clasificar el nivel de tráfico en categorías bajo, medio y elevado.

Durante la fase de transformación, se ha desarrollado un proceso de limpieza, integración y estandarización de los datos, resolviendo incidencias como errores en el formato de la hora o desajustes temporales entre las capturas de las cámaras y los datos meteorológicos. Como resultado, se ha obtenido un dataset funcional y coherente, en formato CSV, que integra información visual, meteorológica y etiquetas de tráfico.

A partir de este conjunto de datos, se ha llevado a cabo una fase de modelado predictivo mediante técnicas de aprendizaje automático, permitiendo estimar el nivel de tráfico en función de variables como la hora del día, la franja horaria, la ubicación de la cámara, la temperatura, la precipitación y el carácter laborable del día.

Como líneas de evolución del proyecto, se contempla la ampliación del volumen y la diversidad del conjunto de datos, incorporando nuevos periodos temporales, condiciones meteorológicas y ubicaciones, así como el desarrollo de una interfaz visual que facilite la consulta de los resultados y el análisis de tendencias de congestión.

En conjunto, TrafiVisión demuestra cómo la combinación de datos abiertos, visión por computador y procesos ETL automatizados permite desarrollar herramientas útiles para el estudio del tráfico urbano y el apoyo a la toma de decisiones en el ámbito de la movilidad.

1.4 Objetivos específicos

1. Analizar y evaluar fuentes de datos abiertas relacionadas con el tráfico urbano y las condiciones meteorológicas, priorizando aquellas que sean accesibles, actualizadas y fiables.

En el desarrollo del proyecto se han seleccionado las cámaras públicas de tráfico del Ayuntamiento de Madrid y la API Open-Meteo, debido a su disponibilidad, fiabilidad y formato estructurado. Como línea de evolución, se contempla la incorporación de fuentes complementarias, como datos de aforos o información de congestión procedente de otros portales

de datos abiertos.


2. Desarrollar scripts de extracción automatizados que permitan obtener los datos de forma periódica y sin intervención manual.
Actualmente, el sistema captura imágenes de tráfico y datos meteorológicos de manera sincronizada cada quince minutos. Esta automatización permite la generación continua del dataset y asegura la coherencia temporal entre las distintas fuentes. En fases posteriores, se prevé ampliar los periodos de captura y añadir mecanismos de monitorización y registro de errores.
3. Estandarizar, depurar y enriquecer la información recopilada para garantizar su consistencia y calidad.
Durante esta fase se han corregido errores de formato, como la denominada "hora fantasma", se han eliminado duplicados y se han incorporado variables derivadas, entre ellas el carácter laborable del día y la franja horaria. Estas transformaciones permiten mejorar la calidad del conjunto de datos y facilitar su posterior análisis.
4. Unificar la información procedente de las distintas fuentes en un dataset estructurado y documentado, preparado para su análisis y modelado.
El dataset resultante (`dataset_final_limpio.csv`) integra información visual, meteorológica y temporal, y permite explorar relaciones entre el tráfico, el clima y el momento del día. Como mejora futura, se plantea la elaboración de un diccionario de datos completo, la inclusión de metadatos descriptivos y la evaluación de otros formatos de almacenamiento para facilitar su reutilización.
5. Aplicar técnicas de aprendizaje automático para el análisis y la predicción del nivel de tráfico urbano.
A partir del dataset generado, se ha llevado a cabo un proceso de modelado mediante algoritmos de clasificación supervisada, orientado a estimar el nivel de tráfico en función de variables

espaciales, temporales y meteorológicas. Este proceso permite evaluar distintos enfoques y seleccionar el modelo con mejor rendimiento para su uso en el sistema.

6. Facilitar el análisis de patrones de movilidad y tráfico mediante la interpretación de los resultados obtenidos.

El sistema desarrollado permite identificar tendencias de congestión asociadas a determinadas franjas horarias, ubicaciones y condiciones climáticas, constituyendo una base sólida para futuras visualizaciones y herramientas de apoyo a la toma de decisiones.

1.5 Planificación



Capítulo 2. TECNOLOGÍAS USADAS

El desarrollo del proyecto **TrafiVision** se apoya en un conjunto de herramientas y tecnologías que permiten automatizar la recopilación, el tratamiento, el análisis y el modelado de datos de tráfico urbano. Estas tecnologías cubren todas las fases del proyecto, desde la extracción de datos hasta su explotación mediante modelos predictivos y una aplicación gráfica final.

A continuación, se describen las principales tecnologías empleadas.

Python 3.9

Python constituye el lenguaje principal del sistema debido a su versatilidad, amplia comunidad y disponibilidad de bibliotecas especializadas en manipulación de datos, visión por computador y aprendizaje automático.

Todo el flujo ETL del proyecto —incluyendo la extracción, limpieza, integración y generación del dataset final— se ha implementado íntegramente en Python.

Visual Studio Code

El entorno de desarrollo utilizado es Visual Studio Code, que facilita la organización del proyecto, la ejecución de scripts desde la terminal y la integración con sistemas de control de versiones. Su uso permite mantener una estructura clara del código y una trazabilidad completa de los cambios realizados durante el desarrollo.

Bibliotecas de Python

El proyecto hace uso de diversas bibliotecas especializadas, entre las que destacan:

- **requests**, utilizada para realizar peticiones HTTP a las distintas fuentes de datos, incluyendo las cámaras de tráfico y la API meteorológica Open-Meteo.
- **pandas**, empleada para la manipulación, limpieza, transformación, unión y exportación de los conjuntos de datos en formato CSV.

- **schedule**, junto con **time** y **datetime**, utilizadas para la automatización de tareas periódicas y la correcta gestión de fechas y horas en el proceso ETL.
- **ultralytics (YOLOv8)**, utilizada para la detección de vehículos en imágenes mediante técnicas de visión por computador. En el proyecto se ha empleado el modelo **YOLOv8n (nano)**, seleccionado por su equilibrio entre precisión y eficiencia computacional.
- **opencv-python**, utilizada de forma indirecta como apoyo al procesamiento de imágenes capturadas por las cámaras de tráfico.
- **torch** y **torchvision**, empleadas como base para la ejecución del modelo YOLOv8 y la inferencia de detección de objetos.
- **scikit-learn**, utilizada para el entrenamiento de modelos de aprendizaje automático supervisado como Árboles de Decisión, Random Forest, KNN y Regresión Logística, así como para la obtención de probabilidades asociadas a cada predicción.
- **joblib**, empleada para la serialización y carga de los modelos entrenados, permitiendo su reutilización dentro de la aplicación final sin necesidad de reentrenamiento.

Open-Meteo API

La API Open-Meteo se utiliza como fuente principal de información meteorológica. Permite obtener datos de temperatura, precipitación y condiciones climáticas en tiempo real para coordenadas específicas, en este caso correspondientes a la ciudad de Madrid. Se trata de una API gratuita y sin necesidad de autenticación, lo que facilita su integración y automatización dentro del sistema.

Cámaras públicas de tráfico del Ayuntamiento de Madrid

El proyecto emplea imágenes procedentes de cámaras públicas de tráfico actualizadas periódicamente. Se accede directamente a los enlaces en

formato JPG de diez cámaras seleccionadas en ubicaciones representativas de la ciudad, como Cibeles, Plaza de Castilla, Gran Vía o Cuatro Caminos. Estas imágenes constituyen la base visual del análisis del tráfico.

Altair AI Studio

Para la fase de modelado y validación de los datos se ha utilizado la herramienta Altair AI Studio. Esta plataforma ha permitido diseñar flujos de aprendizaje automático de forma visual, aplicar técnicas de validación cruzada, comparar distintos algoritmos de clasificación y seleccionar el modelo con mejor rendimiento para la predicción del nivel de tráfico.

Git y GitHub

Git y GitHub se utilizan como herramientas de control de versiones y gestión del proyecto. El repositorio permite almacenar el código, el dataset generado y los artefactos del modelado, facilitando el seguimiento de cambios, la colaboración y la reproducibilidad del sistema desarrollado.

Conclusión sobre las tecnologías utilizadas

La combinación de Python, bibliotecas especializadas, herramientas de visión por computador y plataformas de modelado ha permitido construir un sistema completo, modular y reproducible para el análisis del tráfico urbano. El uso de Altair AI Studio ha facilitado la fase de aprendizaje automático, permitiendo evaluar distintos modelos y seleccionar el más adecuado en función de su rendimiento. En conjunto, las tecnologías empleadas proporcionan una base sólida para el análisis y la predicción del tráfico en entornos urbanos reales.

Capítulo 3. ANALISIS DEL PROBLEMA

Necesidad y motivación

La gestión del tráfico en las grandes ciudades constituye un reto constante debido a la elevada densidad de vehículos y a la complejidad de los patrones de movilidad urbana. En el caso de Madrid, el tráfico genera de forma recurrente episodios de congestión, incremento de los tiempos de desplazamiento y un impacto negativo en la calidad del aire, lo que pone de manifiesto la necesidad de disponer de información actualizada y accesible que permita analizar y comprender el comportamiento del tráfico en distintos contextos.

Aunque el Ayuntamiento de Madrid pone a disposición diversas fuentes de datos abiertos, como cámaras de tráfico o información sobre incidencias, estos datos se presentan de forma fragmentada y en formatos heterogéneos, lo que dificulta su integración y su explotación conjunta de manera automatizada. Del mismo modo, las fuentes meteorológicas externas, como Open-Meteo o AEMET, no se encuentran directamente integradas con los datos de tráfico, a pesar de la influencia directa que las condiciones climáticas ejercen sobre la movilidad urbana.

En este contexto, el proyecto TrafiVison aborda la problemática desde un enfoque práctico y orientado a datos, automatizando la recolección, limpieza e integración de información visual y meteorológica. El resultado es la generación de un dataset unificado que combina ambos tipos de información, facilitando su análisis y posterior modelado. De este modo, el proyecto contribuye a mejorar la accesibilidad y el aprovechamiento de los datos abiertos para el estudio técnico del tráfico urbano y para el desarrollo de soluciones basadas en datos que apoyen la toma de decisiones en movilidad.

Problemas detectados durante el desarrollo

Problemas detectados durante el desarrollo

Durante las primeras fases del desarrollo del proyecto se identificaron diversos retos técnicos relacionados con la calidad, la coherencia y la integración de los datos, así como con las características propias de las fuentes utilizadas.

Uno de los principales problemas detectados fue la inconsistencia en el formato de la hora. En las primeras capturas, algunas entradas incluían una fecha errónea (1900-01-01), lo que afectaba a la coherencia temporal del conjunto de datos. Esta incidencia se resolvió mediante el desarrollo de un script específico de limpieza que estandariza la información horaria y conserva únicamente el valor correspondiente a la hora en formato HH:MM.

Otro reto relevante fue el desfase temporal entre las capturas de las cámaras de tráfico y los datos meteorológicos asociados. Dado que ambas fuentes no se actualizan de forma perfectamente simultánea, se introdujo una tolerancia temporal de ± 2 minutos en el proceso de unión de los datos, permitiendo asociar de manera más precisa la información climática a cada imagen capturada.

Asimismo, se detectó un desbalance en la distribución de las muestras, ya que la mayoría de las imágenes recopiladas corresponden a días sin lluvia. Este desequilibrio puede influir en el rendimiento del modelo predictivo, especialmente en la identificación de situaciones menos frecuentes. Aunque el dataset actual es funcional, este aspecto se tiene en cuenta como una limitación del sistema y como un punto de mejora mediante la ampliación de las capturas en condiciones meteorológicas más diversas.

Por último, se identificaron limitaciones relacionadas con las condiciones de iluminación, especialmente en las imágenes nocturnas. La presencia de reflejos, sombras y contrastes elevados dificulta en algunos casos la detección precisa de vehículos por parte del modelo YOLOv8. Para mitigar este efecto, se han ajustado los parámetros de confianza y los filtros aplicados durante el análisis de las imágenes.

Estos problemas se han abordado de forma progresiva a lo largo del desarrollo del proyecto, priorizando en todo momento la calidad del dato, la coherencia temporal y la correcta integración de las distintas fuentes de información.

Casos de uso actuales y previstos

1. En su estado actual, TrafiVisión permite analizar el comportamiento del tráfico urbano en distintos puntos de la ciudad de Madrid, combinando variables temporales, espaciales y meteorológicas como la franja horaria, la temperatura, la presencia de lluvia, el tipo de día (laborable o no laborable) y la ubicación de la cámara. A partir del dataset generado y del proceso de modelado desarrollado, el sistema da soporte a diversos casos de uso tanto actuales como previstos como evolución futura del proyecto.
2. En primer lugar, el sistema permite realizar un análisis exploratorio del tráfico urbano, facilitando el estudio de cómo varía el nivel de congestión en función de la hora del día, las condiciones meteorológicas o el carácter laborable del día. Este tipo de análisis resulta útil para identificar patrones generales de movilidad y comportamientos recurrentes del tráfico en entornos urbanos.
3. En segundo lugar, TrafiVisión permite la comparación entre distintas ubicaciones, posibilitando identificar qué zonas presentan mayores niveles de congestión en determinados horarios o bajo condiciones específicas. Este enfoque comparativo resulta especialmente relevante para analizar diferencias estructurales entre calles y áreas representativas de la ciudad.
4. Asimismo, el proyecto incorpora actualmente un caso de uso orientado a la predicción del tráfico. A partir del dataset final y del modelo de aprendizaje automático entrenado, la aplicación permite estimar el nivel de tráfico esperado para una combinación concreta de condiciones introducidas por el usuario. Este caso de uso se materializa en una interfaz gráfica desarrollada en Python, que facilita la

interacción con el modelo y la visualización de los resultados de forma clara y comprensible.

5. Como línea de evolución futura, se contempla la ampliación de estos casos de uso mediante la incorporación de un mayor volumen de datos, la mejora del modelo predictivo y la integración de nuevas variables relevantes. Estas mejoras permitirían convertir TrafiVison en una herramienta de apoyo más avanzada para la toma de decisiones en el ámbito de la movilidad urbana, con potencial aplicación en planificación del tráfico, análisis de congestión y estudios de movilidad.

Requisitos del problema

Los datos utilizados en el proyecto deben proceder de fuentes oficiales y abiertas, garantizando su fiabilidad, accesibilidad y continuidad en el tiempo. Asimismo, la información debe mantenerse actualizada mediante un proceso de recopilación automatizado que no requiera intervención manual por parte del usuario.

El sistema debe asegurar la coherencia temporal entre las imágenes de tráfico capturadas y los datos meteorológicos asociados, de modo que cada registro del dataset represente una situación real y consistente en un instante concreto de tiempo.

El conjunto de datos generado debe presentarse de forma limpia, estructurada y normalizada, quedando preparado para su análisis mediante técnicas de aprendizaje automático, así como para su uso en procesos de análisis exploratorio y visualización de datos.

El proceso ETL implementado debe ser reproducible y escalable, permitiendo su ejecución periódica y su adaptación a un mayor volumen de datos o a la incorporación de nuevas fuentes de información sin necesidad de realizar cambios sustanciales en la arquitectura del sistema.

Perspectiva futura

En las siguientes fases de evolución del sistema, el proyecto se orientará principalmente a la ampliación y diversificación del conjunto de datos ya existente, incorporando nuevos periodos temporales y una mayor variedad de situaciones dentro de las mismas ubicaciones analizadas. Esta ampliación permitiría mejorar la capacidad de generalización del modelo y reforzar la representación de escenarios menos frecuentes, como condiciones meteorológicas adversas o episodios de tráfico elevado.

Asimismo, se contempla la mejora del proceso de detección de vehículos en condiciones nocturnas, mediante el ajuste de parámetros del modelo de visión por computador y la optimización de los filtros aplicados durante el análisis de imágenes. Estas mejoras permitirían aumentar la fiabilidad de las detecciones en entornos con baja iluminación, donde actualmente se presentan mayores dificultades.

En cuanto al análisis predictivo, el proyecto ya dispone de un modelo de aprendizaje automático capaz de estimar el nivel de tráfico a partir de variables temporales, espaciales y meteorológicas. Como línea de mejora, se prevé optimizar este modelo mediante la incorporación de un mayor volumen de datos y la evaluación de distintos ajustes que permitan mejorar su rendimiento, especialmente en la clasificación de situaciones de alta congestión.

Por último, se plantea el desarrollo de una interfaz visual sencilla que permita interactuar con el modelo predictivo, facilitando la introducción de distintas condiciones de entrada y la consulta del nivel de tráfico estimado. De este modo, TrafiVison evolucionaría desde un sistema centrado en la recopilación y el análisis de datos hacia una herramienta más accesible y orientada a la interpretación práctica de los resultados obtenidos.

Análisis del problema

Necesidad y motivación

La gestión del tráfico urbano en la ciudad de Madrid representa un desafío constante, especialmente en aquellas zonas con alta densidad de circulación. Las congestiones diarias, el incremento de los tiempos de desplazamiento y el impacto medioambiental asociado al tráfico hacen necesario disponer de datos reales y actualizados que permitan analizar los patrones de movilidad y anticipar situaciones de elevada ocupación vial.

Aunque el Ayuntamiento de Madrid ofrece acceso a múltiples fuentes de datos abiertos, entre ellas las cámaras de tráfico en tiempo real, esta información suele presentarse de forma dispersa y sin una integración directa con otros factores relevantes, como las condiciones meteorológicas. Esta falta de conexión entre fuentes dificulta la realización de análisis conjuntos que permitan extraer conclusiones útiles sobre el comportamiento del tráfico.

El proyecto TrafiVison se desarrolla con el propósito de unificar y automatizar la recopilación de información visual y meteorológica, generando un conjunto de datos coherente y preparado para su análisis. Para ello, se han seleccionado diez cámaras de tráfico ubicadas en puntos estratégicos de la ciudad, en los que se registran flujos representativos de distintos tipos de vías y entornos urbanos. Las ubicaciones seleccionadas son las siguientes:

- Calle Princesa – Serrano Jover
- Alonso Martínez
- Cibeles
- Calle Alcalá – Velázquez
- Paseo de la Castellana – Santiago Delgado
- Avenida de América – Francisco Silvela
- Callao – Gran Vía
- Cuatro Caminos

- Paseo del Prado – Huertas
- Plaza de Castilla (Norte)

Estas localizaciones combinan zonas céntricas, avenidas principales y ejes de conexión entre distintos barrios, lo que permite capturar una amplia variedad de patrones de tráfico a lo largo del día. Además, la diversidad de ubicaciones garantiza diferentes condiciones de iluminación y entorno, aspectos relevantes para el entrenamiento y evaluación de modelos de visión por computador.

El sistema desarrollado captura imágenes de estas cámaras de forma periódica cada quince minutos, alineando las capturas a las horas en punto y a los cuartos (:00, :15, :30 y :45). Estas imágenes se combinan con los datos meteorológicos obtenidos mediante la API Open-Meteo, que proporciona información sobre la temperatura y las precipitaciones en la ciudad de Madrid, permitiendo asociar a cada captura de tráfico su contexto climático correspondiente.

Problemas detectados durante el desarrollo

Durante la fase de implementación del sistema se identificaron y resolvieron diversos retos técnicos relacionados con la calidad, la coherencia y la sincronización de los datos utilizados.

Uno de los principales problemas detectados fue el formato inconsistente de la hora. En las primeras versiones del dataset, algunos registros incluían la fecha errónea “1900-01-01” junto con la hora de captura, lo que generaba errores durante el proceso de unificación de los distintos archivos CSV. Esta incidencia se resolvió mediante el desarrollo de un script específico de limpieza que normaliza la información horaria y conserva únicamente el valor correspondiente a la hora en formato HH:MM.

Otro reto relevante fue el desfase temporal entre las capturas de las cámaras de tráfico y los datos meteorológicos asociados. Dado que la frecuencia de actualización de las cámaras y de la API meteorológica no coincide de forma exacta, se introdujo una tolerancia temporal de ± 2 minutos en el proceso de unión de los datos. Este enfoque permitió asociar de manera más precisa la información climática a cada imagen capturada.

Asimismo, se detectó un desbalance en la distribución de los datos, ya que la mayoría de las capturas corresponden a días sin lluvia y a franjas horarias diurnas. Esta representación desigual puede influir en el rendimiento de los modelos predictivos, especialmente en la identificación de situaciones menos frecuentes. Este aspecto se considera una limitación del dataset actual y un punto de mejora mediante la ampliación temporal de la recolección de datos.

Por último, se observaron limitaciones en la detección de vehículos en condiciones nocturnas. La baja iluminación, la presencia de reflejos y el elevado contraste en determinadas zonas afectan a la precisión del modelo YOLOv8. Para mitigar este efecto, se han evaluado ajustes en los parámetros de detección y la aplicación de filtros adicionales durante el análisis de las imágenes.

En conjunto, estos problemas se abordaron de forma progresiva a lo largo del desarrollo del proyecto, priorizando en todo momento la coherencia temporal y la calidad del dato frente al volumen de información recolectada.

Casos de uso actuales y previstos

En su estado actual, TrafiVisión permite analizar el comportamiento del tráfico urbano en distintos puntos de la ciudad de Madrid a partir de la integración de información visual, temporal y meteorológica. El sistema da soporte a varios casos de uso relevantes, tanto en la fase final del proyecto como en posibles ampliaciones futuras.

En primer lugar, el sistema permite realizar un análisis exploratorio del tráfico urbano, facilitando el estudio de cómo varía la intensidad del tráfico en

función de la hora del día, la ubicación de la cámara y las condiciones meteorológicas. Este análisis resulta útil para identificar patrones recurrentes de movilidad, así como franjas horarias con mayor o menor nivel de congestión.

Asimismo, TrafiVisión posibilita la comparación entre distintas zonas de la ciudad, permitiendo observar diferencias de ocupación entre calles céntricas, como Gran Vía o Cibeles, y zonas de conexión o acceso, como Plaza de Castilla o Cuatro Caminos. Este enfoque comparativo contribuye a comprender mejor el comportamiento diferencial del tráfico según el tipo de vía y su función dentro de la red urbana.

Además, el proyecto incorpora una interfaz gráfica desarrollada en Python que permite interactuar directamente con el modelo predictivo. A través de esta interfaz, el usuario puede seleccionar distintas combinaciones de variables de entrada —como ubicación, franja horaria, tipo de día, condiciones meteorológicas y temperatura— y obtener una estimación del nivel de tráfico junto con las probabilidades asociadas a cada categoría (bajo, medio o alto). Esta funcionalidad convierte a TrafiVisión en una herramienta práctica de consulta y análisis, más allá del tratamiento puramente teórico de los datos.

Como posible evolución futura, el sistema podría ampliarse mediante la incorporación de nuevos puntos de captura, un mayor volumen de datos históricos o mejoras en la visualización de resultados, reforzando así su utilidad como herramienta de apoyo al análisis y la toma de decisiones en el ámbito de la movilidad urbana.

Requisitos del problema

- Los datos utilizados en el proyecto deben ser reales, abiertos y proceder de fuentes oficiales, garantizando su fiabilidad, disponibilidad y validez para el análisis del tráfico urbano. Asimismo, la obtención de dichos datos debe realizarse de forma automatizada, sin requerir intervención manual, asegurando la continuidad y repetibilidad del sistema.

- El proceso ETL implementado debe poder ejecutarse de manera periódica y reproducible, permitiendo la actualización continua del conjunto de datos y garantizando la consistencia del sistema a lo largo del tiempo. Este proceso debe ser escalable, de modo que pueda adaptarse a un mayor volumen de información o a la incorporación de nuevas fuentes sin necesidad de modificar su estructura principal.
- La información temporal debe mantenerse correctamente sincronizada entre las capturas de las cámaras de tráfico y los datos meteorológicos asociados, de forma que cada registro del dataset represente una situación real y coherente. Para ello, el sistema debe gestionar posibles desfases temporales entre las distintas fuentes de datos.
- El dataset final generado debe presentarse de forma limpia, estructurada y coherente, preparado tanto para su análisis estadístico y exploratorio como para su uso en modelos predictivos de aprendizaje automático. Además, dicho conjunto de datos debe ser compatible con herramientas de visualización y con la interfaz gráfica desarrollada en el proyecto, permitiendo la consulta interactiva y la interpretación clara de los resultados obtenidos.

Perspectiva futura

En fases posteriores de evolución del sistema, se plantea ampliar el periodo de observación utilizando la infraestructura ya desarrollada, con el objetivo de incorporar un mayor número de situaciones y condiciones meteorológicas, como episodios de lluvia más intensos, variaciones estacionales o cambios en el comportamiento del tráfico a lo largo del año. Esta ampliación permitiría mejorar la representatividad del conjunto de datos y reforzar la capacidad de generalización de los modelos predictivos implementados.

En cuanto al análisis predictivo, el proyecto ya cuenta con modelos de aprendizaje automático funcionales capaces de estimar el nivel de tráfico a partir de variables temporales, espaciales y meteorológicas, integrados directamente en la aplicación. Como línea de mejora, se contempla optimizar estos modelos mediante la incorporación de un mayor volumen de datos, el ajuste de hiperparámetros y la evaluación de nuevas técnicas de clasificación

que permitan mejorar especialmente la detección de situaciones de tráfico elevado.

Asimismo, aunque el sistema dispone actualmente de una interfaz gráfica operativa para la consulta de predicciones, se plantea su evolución mediante la incorporación de nuevas funcionalidades, como visualizaciones históricas, comparativas entre ubicaciones o franjas horarias, y una mayor capacidad de exploración de los datos por parte del usuario. Estas mejoras permitirían una interpretación más completa y contextualizada de los resultados obtenidos.

De este modo, TrafiVisión evolucionaría desde una herramienta de análisis y predicción del tráfico urbano hacia un sistema más robusto, flexible y orientado al apoyo a la toma de decisiones, manteniendo un alcance realista y alineado con los objetivos planteados en el proyecto.

Capítulo 4. PROPUESTA DE SOLUCIÓN (DISEÑO)

En este capítulo se describe la propuesta de solución adoptada para abordar el problema del análisis y la predicción del tráfico urbano en la ciudad de Madrid. Se detalla cómo se ha diseñado el sistema desde un punto de vista técnico y funcional, explicando la arquitectura general, la división del problema en componentes independientes y las tecnologías empleadas en cada fase del proceso.

La solución planteada se basa en una arquitectura modular que permite automatizar de extremo a extremo el flujo de datos, desde su obtención hasta su análisis. Este enfoque facilita la escalabilidad del sistema, el mantenimiento del código y la incorporación progresiva de nuevas funcionalidades sin alterar el núcleo del proyecto.

El diseño del sistema se apoya en un proceso ETL (Extracción, Transformación y Carga) como eje central de la arquitectura. A partir de este proceso, se construye un dataset propio y coherente que sirve como base para el análisis exploratorio y el posterior modelado predictivo del tráfico. Sobre esta base de datos estructurada se añade una capa de análisis mediante técnicas de aprendizaje automático, orientada a clasificar y estimar niveles de tráfico en función de variables temporales y meteorológicas.

Desde el punto de vista tecnológico, la solución combina scripts desarrollados en Python para la automatización del proceso ETL con herramientas de análisis y modelado que permiten validar distintos enfoques de aprendizaje automático. Esta separación entre la fase de generación del dato y la fase de experimentación facilita la validación de modelos y la toma de decisiones fundamentadas sobre qué técnicas resultan más adecuadas para el problema planteado.

El diseño propuesto no se limita únicamente a la recolección de datos, sino que establece una base sólida para la evolución del sistema hacia escenarios más avanzados, como la predicción del tráfico y su visualización mediante interfaces interactivas. De este modo, TrafiVison se concibe como una solución

integral que conecta datos abiertos, visión por computador y técnicas de análisis avanzado dentro de una arquitectura coherente y reproducible.

4.1 Organización de las subtareass

El diseño del proyecto TrafiVision se centra en la creación de una arquitectura modular orientada a automatizar la captura, limpieza y análisis de datos de tráfico en la ciudad de Madrid.

La solución se apoya en un proceso ETL (Extracción, Transformación y Carga) completamente automatizado, sobre el que se ha comenzado a trabajar una capa de modelado predictivo y que servirá como base para futuras visualizaciones analíticas.

El sistema se divide en tres grandes módulos:

- Extracción automática de datos (E): obtención de imágenes de tráfico y datos meteorológicos.
- Transformación y limpieza (T): depuración, estandarización y unificación de los datos en un único dataset.
- Carga y análisis (L): almacenamiento del dataset final y preparación para el análisis y el modelado predictivo.

Cada módulo se implementa mediante scripts desarrollados en Python, integrando librerías como requests, pandas, schedule, ultralytics y os, junto con una estructura de carpetas organizada para almacenar tanto las imágenes como los archivos CSV generados en cada fase.

Arquitectura general

El proyecto TrafiVison se ejecuta sobre una arquitectura software organizada en tres niveles claramente diferenciados, que permiten separar la obtención de los datos, su procesamiento y su análisis posterior.

Nivel de datos:

Recopilación automática de información procedente de fuentes abiertas y oficiales, concretamente de las cámaras públicas de tráfico del Ayuntamiento de Madrid y de la API meteorológica Open-Meteo. Este nivel se encarga de la adquisición periódica de imágenes y datos climáticos sin intervención manual.

Nivel de procesamiento:

Conjunto de scripts desarrollados en Python responsables de la limpieza, transformación e integración de los datos. En este nivel se normaliza la información temporal, se depuran inconsistencias y se genera un dataset final estructurado en formato CSV, preparado para su análisis y uso en modelos de aprendizaje automático.

Nivel de análisis y visualización:

Sobre el dataset final se aplican técnicas de aprendizaje automático para la predicción del nivel de tráfico. Esta fase se ha abordado tanto mediante herramientas de modelado visual, como Altair AI Studio, como mediante una aplicación de escritorio desarrollada en Python que permite visualizar el dataset y realizar predicciones de forma interactiva.

El sistema se ejecuta de forma local y no requiere hardware adicional más allá del equipo de desarrollo. No obstante, la arquitectura propuesta es modular y escalable, por lo que podría adaptarse fácilmente a entornos en la nube o a servidores externos en futuras ampliaciones del proyecto.

Organización de subtarefas

Subtarea 1: Selección y análisis de fuentes de datos

Descripción

Se seleccionaron fuentes de información públicas y actualizables en tiempo real, priorizando su fiabilidad, accesibilidad y formato estructurado. Las fuentes elegidas fueron:

- Cámaras de tráfico del Ayuntamiento de Madrid, que proporcionan imágenes en formato JPG actualizadas periódicamente.
- API de Open-Meteo, que ofrece datos meteorológicos en formato JSON, incluyendo temperatura y precipitaciones.

Recursos

- Librerías: `requests`, `os`, `datetime`
- Formatos: `.jpg` (imágenes) y `.json` (datos meteorológicos)

Motivo de elección

Ambas fuentes son abiertas, estables y presentan una estructura regular que facilita su integración en procesos automatizados y reproducibles.

Subtarea 2: Descarga y almacenamiento de imágenes

Descripción

Mediante el script `etl_camaras_madrid.py` se implementó un proceso automatizado que descarga imágenes de diez cámaras seleccionadas en puntos clave de Madrid (Alcalá, Cibeles, Plaza de Castilla, Gran Vía, entre otros) con una frecuencia aproximada de 15 minutos.

Cada imagen se almacena localmente incluyendo en su nombre la ubicación, la fecha y la hora de captura.

Entrada

- URLs de las cámaras seleccionadas.

Salida

- Imágenes almacenadas localmente con nombre estructurado (`calle_fecha_hora.jpg`).

Recursos

- Librerías: `requests`, `os`, `datetime`
- Carpeta destino: `imagenesTrafico`

Comentarios

Durante las primeras pruebas se detectaron errores de conexión puntuales en algunas cámaras, lo que permitió ajustar el proceso para mejorar su estabilidad y tolerancia a fallos.

Subtarea 3: Obtención de datos meteorológicos

Descripción

Se desarrolló el script `etl_tiempo.py`, encargado de consultar la API de Open-Meteo para obtener datos meteorológicos en tiempo real.

El proceso se sincroniza con la captura de imágenes y almacena los resultados en un archivo CSV.

Entrada

- Coordenadas geográficas de Madrid (40.4168, -3.7038).

Salida

- Archivo `tiempo_madrid.csv` con columnas de fecha, hora, temperatura y precipitaciones.

Recursos

- Librerías: `requests`, `pandas`, `schedule`
- Carpeta destino: `csv`

Incidencias

Inicialmente se detectó un formato incorrecto en la hora (fecha "1900-01-01"), que fue corregido posteriormente en la fase de limpieza.

Subtarea 4: Análisis de imágenes mediante YOLOv8

Descripción

En esta fase se aplicó el modelo YOLOv8, a través de la librería `ultralytics`, para analizar cada imagen descargada y detectar vehículos.

El script `yolo_final.py` procesa las imágenes y genera un CSV con el número de vehículos detectados y una clasificación del nivel de tráfico (bajo, medio o alto).

Entrada

- Carpeta `imagenesTrafico`.

Salida

- Archivo `yolo_final.csv` con columnas de imagen, número de vehículos y nivel de tráfico.

Recursos

- Librerías: `ultralytics`, `pandas`, `os`
- Modelo: `yolov8n.pt` (versión ligera optimizada para ejecución local)

Resultados

Se generaron etiquetas automáticas para aproximadamente 3.000 imágenes, constituyendo la base principal del dataset final.

Subtarea 5: Limpieza, integración y generación del dataset final

Descripción

Se integraron los archivos generados en las fases anteriores mediante el script `merge_datasets_final.py`.

Durante este proceso se corrigieron formatos, se eliminaron inconsistencias y se añadieron variables derivadas como:

- Día laborable / no laborable
- Franja horaria (madrugada, mañana, mediodía, tarde, noche)

Entrada

- Archivos CSV generados en las fases previas.

Salida

- Archivo `dataset_final_limpio.csv`.

Recursos

- Librerías: `pandas`, `datetime`, `os`
- Carpeta destino: `csv`

Comentarios

Se detectaron pequeños desfases temporales entre los datos de cámaras y clima, que se resolvieron mediante una coincidencia por rangos horarios.

Subtarea 6: Modelado predictivo del tráfico

Descripción

Con el dataset limpio y estructurado, se desarrolló la fase de modelado predictivo del tráfico.

Inicialmente se realizaron experimentos mediante herramientas de modelado visual (Altair AI Studio) para evaluar distintos algoritmos de clasificación.

Posteriormente, el modelado se trasladó a Python, entrenando modelos supervisados como árboles de decisión y Random Forest, que fueron almacenados y reutilizados dentro de la aplicación final.

Entrada

- `dataset_final_limpio.csv`

Resultado

- Modelos entrenados y serializados (`.joblib`) capaces de estimar el nivel de tráfico a partir de variables temporales, espaciales y meteorológicas.

Subtarea 7: Desarrollo de la aplicación e interfaz gráfica

Descripción

Se desarrolló una aplicación de escritorio en Python que integra el conjunto de funcionalidades del proyecto.

La aplicación permite visualizar el dataset completo en formato tabular, realizar predicciones de tráfico seleccionando distintas condiciones de entrada y mostrar la estructura interna de los modelos (por ejemplo, el árbol de decisión).

Recursos

- Librerías: `customtkinter`, `pandas`, `joblib`, `scikit-learn`, `matplotlib`

- Entorno: ejecución local

Resultado

- Aplicación funcional e interactiva que conecta el proceso ETL, el modelado predictivo y la visualización de resultados.

Subtarea 8: Versionado y documentación

Descripción

Todo el proyecto se ha versionado en un repositorio público de GitHub, permitiendo mantener trazabilidad completa del desarrollo, control de versiones y una organización clara del código, los datasets y la documentación.

Recursos

- Herramientas: Git y GitHub
- Contenido: scripts ETL, aplicación gráfica, modelos entrenados, datasets y documentación del proyecto.

Capítulo 5. DESARROLLO / IMPLEMENTACIÓN

En este capítulo se describe la implementación real del sistema TrafiVison, detallando las funcionalidades desarrolladas y su grado de integración dentro de la solución final.

Implementación realizada

En la fase final del proyecto, TrafiVison cuenta con una implementación completa y funcional que integra la obtención de datos reales, su procesamiento automatizado, el modelado predictivo y una interfaz gráfica de consulta.

En primer lugar, se ha desarrollado un proceso ETL automatizado que recopila imágenes de diez cámaras públicas de tráfico del Ayuntamiento de Madrid con una frecuencia aproximada de 15 minutos. Estas imágenes se almacenan de forma estructurada, incorporando información relativa a la ubicación, la fecha y la hora de captura. De forma paralela, se obtienen datos meteorológicos mediante la API Open-Meteo, registrando variables como la temperatura y la precipitación asociadas a la ciudad de Madrid.

Sobre las imágenes capturadas se ha integrado un módulo de visión por computador basado en YOLOv8, que permite detectar vehículos y estimar el nivel de tráfico. A partir del número de vehículos detectados, cada imagen se clasifica automáticamente en una de las categorías de tráfico definidas: bajo, medio o alto. Este análisis genera etiquetas automáticas que constituyen una de las variables principales del dataset.

Posteriormente, se ha implementado una fase de transformación y limpieza de los datos, en la que se corrigen errores de formato, se sincronizan las distintas fuentes de información y se generan variables derivadas como la franja horaria o el tipo de día (laborable o no laborable). El resultado de este proceso es un dataset unificado, limpio y coherente en formato CSV, que constituye la base de datos principal del proyecto.

A partir de este dataset, se ha desarrollado la fase de modelado predictivo del tráfico. Inicialmente, se realizaron experimentos mediante la herramienta Altair AI Studio para evaluar distintos algoritmos de clasificación. Como resultado de esta fase exploratoria, se identificaron los modelos basados en árboles como los más adecuados en términos de equilibrio entre precisión e interpretabilidad. Posteriormente, estos modelos se entrenaron e implementaron directamente en Python, utilizando librerías de aprendizaje automático, y se almacenaron para su reutilización dentro del sistema.

Finalmente, se ha desarrollado una aplicación gráfica de escritorio en Python que integra las distintas funcionalidades del proyecto. Esta interfaz permite visualizar el dataset completo en formato tabular, introducir distintas condiciones de entrada (calle, franja horaria, tipo de día, lluvia y temperatura) y obtener una predicción del nivel de tráfico mediante los modelos entrenados. Asimismo, la aplicación permite visualizar la estructura interna del modelo de árbol de decisión, facilitando la interpretación de los resultados obtenidos.

Estado actual del sistema

En su estado actual, TrafiVison constituye una solución completa que integra datos reales, procesamiento automatizado, modelado predictivo y visualización interactiva. El sistema permite tanto el análisis del tráfico urbano como la realización de predicciones a partir de variables temporales, espaciales y meteorológicas, cumpliendo los objetivos planteados para el proyecto.

Implementación prevista como mejora futura

Como líneas de mejora y evolución del sistema, se contemplan las siguientes ampliaciones:

- Continuar la recolección de datos para aumentar el volumen del dataset y mejorar la representación de situaciones menos frecuentes, como episodios de lluvia intensa o tráfico elevado.
- Optimizar los modelos predictivos mediante la incorporación de nuevos datos y el ajuste de sus parámetros, con especial atención a la mejora

de la clasificación de escenarios de alta congestión.

- Ampliar las funcionalidades de la interfaz gráfica, incorporando nuevas opciones de visualización y análisis comparativo entre distintas ubicaciones o periodos temporales.

Estas mejoras se apoyan en la infraestructura ya implementada y permitirían evolucionar el sistema sin modificar su arquitectura general, consolidando TrafiVison como una herramienta más robusta para el análisis y la predicción del tráfico urbano.

Capítulo 6. Modelado

Modelado

Estado actual del modelado

En la fase actual del proyecto TrafiVisión, el trabajo de modelado predictivo se ha centrado en la preparación, validación e integración del dataset base como fundamento para la estimación del nivel de tráfico urbano.

Actualmente, el proyecto dispone de un conjunto de datos completamente integrado y depurado, generado de forma automatizada a partir de tres fuentes principales:

- Imágenes de tráfico obtenidas en tiempo real desde diez cámaras públicas del Ayuntamiento de Madrid.
- Datos meteorológicos proporcionados por la API Open-Meteo, que incluyen variables como temperatura y precipitación.
- Etiquetas de tráfico generadas automáticamente mediante el modelo de visión por computador YOLOv8, que clasifica cada imagen en niveles de tráfico bajo, medio o alto en función del número de vehículos detectados.

El resultado de este proceso es el archivo **dataset_final_limpio.csv**, un conjunto de datos estructurado, coherente y preparado para su utilización en tareas de análisis y aprendizaje automático.

Cada registro del dataset combina información temporal, climática y de localización, junto con variables derivadas que enriquecen el análisis, entre las que se incluyen:

- Tipo de día (laborable o no laborable).

- Franja horaria (madrugada, mañana, mediodía, tarde o noche).
- Nivel de tráfico estimado.

A partir de este dataset, se ha desarrollado la fase de modelado predictivo mediante técnicas de clasificación supervisada. Inicialmente, se realizaron experimentos comparativos con distintos algoritmos para evaluar su comportamiento y rendimiento. Como resultado de esta fase, los modelos basados en árboles demostraron un equilibrio adecuado entre precisión, estabilidad e interpretabilidad.

Los modelos seleccionados han sido posteriormente entrenados e integrados directamente en el entorno Python del proyecto, permitiendo su utilización dentro de la aplicación gráfica desarrollada. De este modo, el sistema es capaz de generar predicciones del nivel de tráfico a partir de combinaciones coherentes de variables temporales, espaciales y meteorológicas, utilizando como base el conocimiento aprendido a partir del dataset real.

En su estado actual, el modelado constituye una parte plenamente funcional del sistema TrafiVison, validando tanto la calidad del conjunto de datos generado como la viabilidad del enfoque predictivo adoptado.

Objetivo del modelado

El objetivo principal del modelado en TrafiVision es **predecir el nivel de tráfico** a partir de variables meteorológicas, temporales y contextuales presentes en el dataset generado.

El modelo busca identificar patrones de congestión urbana y estimar la intensidad del tráfico en distintas zonas de Madrid en función de factores como la franja horaria, la temperatura, la presencia de lluvia y el tipo de día (laborable o no laborable).

Este modelado permite validar que el conjunto de datos construido contiene información relevante para la predicción del tráfico y sienta las bases para futuras aplicaciones, como sistemas de apoyo a la toma de decisiones o herramientas de visualización que faciliten el análisis de la movilidad urbana.

Herramientas de modelado

Para la creación y evaluación de los modelos predictivos se han empleado plataformas de inteligencia artificial visuales que permiten trabajar directamente con conjuntos de datos en formato CSV sin necesidad de desarrollar código adicional.

En concreto, el modelado se ha realizado utilizando **Altair AI Studio (RapidMiner)**, que ofrece un entorno gráfico para diseñar flujos de trabajo de aprendizaje automático, entrenar modelos, validarlos y comparar su rendimiento de forma estructurada.

Esta herramienta ha permitido:

- Conectar directamente el dataset generado (dataset_final_limpio.csv).
- Definir las variables de entrada y la variable objetivo (nivel de tráfico).
- Probar distintos algoritmos de clasificación.
- Evaluar los resultados mediante validación cruzada y métricas de rendimiento.

El uso de una plataforma visual facilita la comprensión del proceso de modelado y la comparación entre algoritmos, además de servir como base para una futura integración del modelo en aplicaciones externas o interfaces de visualización.

Fases del proceso de modelado

1. Preparación del dataset

En primer lugar, se realizó la verificación del formato y la consistencia del archivo `dataset_final_limpio.csv`, comprobando que no existieran valores nulos, errores de formato ni incoherencias temporales.

El dataset fue cargado directamente en la plataforma Altair AI Studio, donde se seleccionaron únicamente las variables relevantes para el proceso de modelado.

Para la evaluación de los modelos no se utilizó una simple división entrenamiento/prueba, sino un esquema de **validación cruzada (Cross Validation)** con 10 particiones, lo que permite obtener resultados más robustos y reducir el riesgo de sobreajuste, especialmente teniendo en cuenta el tamaño limitado del conjunto de datos.

2. Selección de variables

A partir del dataset final, se definieron como variables de entrada aquellas relacionadas con el contexto temporal y meteorológico:

- Temperatura
- Lluvia (litros/m²)
- Hora
- Franja horaria
- Tipo de día (laborable / no laborable)
- Calle (ubicación de la cámara)

Como variable objetivo se estableció el campo **nivel_trafico**, que clasifica cada registro en tráfico bajo, medio o elevado.

Esta selección permite analizar la influencia combinada del clima, el tiempo y la localización sobre la intensidad del tráfico.

3. Entrenamiento de modelos

Durante la fase de modelado se entrenaron y compararon distintos algoritmos de clasificación supervisada disponibles en Altair AI Studio, utilizando el mismo esquema de validación cruzada para todos ellos. Los modelos evaluados fueron:

- Árbol de decisión (Decision Tree)
- Random Forest
- Gradient Boosted Trees
- Naive Bayes
- k-Nearest Neighbors (k-NN)



Cada modelo fue entrenado automáticamente sobre las particiones definidas en la validación cruzada, manteniendo las mismas variables de entrada y la misma variable objetivo, con el fin de realizar una comparación justa entre algoritmos.



4. Evaluación y validación

El rendimiento de los modelos se evaluó principalmente mediante la métrica de **accuracy**, acompañada del análisis de la matriz de confusión, que permite observar el comportamiento del modelo en cada una de las clases (bajo, medio y elevado).

Los resultados obtenidos muestran que el **árbol de decisión** es el modelo que ofrece un mejor equilibrio entre simplicidad, interpretabilidad y rendimiento, alcanzando una precisión aproximada del **73%**, ligeramente superior al resto de algoritmos probados.

Este modelo se selecciona como referencia para el proyecto, teniendo en cuenta que el tamaño del dataset es todavía reducido (alrededor de 3.000 registros) y que un mayor volumen de datos en distintas condiciones permitiría mejorar la capacidad predictiva en el futuro.





Resultados esperados

En el estado actual del proyecto, se espera que el modelo predictivo sea capaz de **identificar el nivel de tráfico de forma consistente** a partir de

variables temporales y meteorológicas, como la hora del día, la franja horaria, la temperatura y la presencia de lluvia. Los resultados obtenidos durante la fase de experimentación muestran que el modelo alcanza una precisión cercana al 73%, lo que se considera adecuado teniendo en cuenta el volumen y la distribución del dataset disponible.

A corto plazo, el objetivo es **consolidar y estabilizar el rendimiento del modelo**, asegurando su correcta generalización dentro de las clases de tráfico bajo, medio y elevado. A medio plazo, se plantea la ampliación del conjunto de datos con nuevas capturas que permitan mejorar la representación de situaciones menos frecuentes, lo que contribuiría a incrementar la precisión y fiabilidad de las predicciones.

Una vez validado y optimizado, el modelo podrá integrarse dentro del pipeline de TrafiVision, de manera que los nuevos lotes de datos procesados —imágenes y condiciones meteorológicas— puedan utilizarse tanto para alimentar el sistema de predicción como para reentrenar el modelo de forma periódica.

Limitaciones del modelo

El modelo predictivo desarrollado presenta una serie de limitaciones que deben tenerse en cuenta a la hora de interpretar los resultados obtenidos. Estas limitaciones están directamente relacionadas con las características del conjunto de datos disponible y con el alcance temporal del proyecto.

En primer lugar, el tamaño del dataset es relativamente reducido, con aproximadamente 3.000 registros. Aunque este volumen ha sido suficiente para validar la viabilidad del enfoque predictivo y obtener resultados coherentes, limita la capacidad del modelo para generalizar ante situaciones poco frecuentes o atípicas.

Asimismo, el conjunto de datos se ha generado durante un periodo de tiempo acotado, lo que implica que no se han podido recoger muestras representativas de distintas épocas del año. En consecuencia, el modelo no ha sido expuesto a variaciones estacionales más amplias, como cambios significativos de temperatura, patrones de tráfico propios de vacaciones o eventos puntuales.

Otra limitación relevante es el desbalance entre las clases de tráfico. La mayoría de los registros corresponden a situaciones de tráfico bajo o medio, mientras que los casos de tráfico elevado son menos frecuentes. Este desequilibrio afecta especialmente a la precisión del modelo a la hora de identificar escenarios de alta congestión.

Por último, la calidad de las predicciones depende en gran medida de la precisión de la detección visual realizada por el modelo YOLOv8. En condiciones de baja iluminación o presencia de reflejos, especialmente durante la noche, la detección de vehículos puede verse afectada, lo que repercute indirectamente en el rendimiento del modelo predictivo.

Estas limitaciones no invalidan los resultados obtenidos, pero sí ponen de manifiesto la necesidad de ampliar el conjunto de datos y extender el periodo de observación para mejorar la robustez y la fiabilidad del sistema en futuras iteraciones.

Separación entre fase experimental y fase de despliegue

El proceso de modelado desarrollado en TrafiVision se ha planteado siguiendo una separación clara entre la fase de experimentación y la fase de integración o despliegue del modelo, tal y como se realiza habitualmente en proyectos reales de análisis de datos y aprendizaje automático.

Durante la fase experimental, se ha utilizado Altair AI Studio como entorno de trabajo para el entrenamiento, validación y comparación de distintos algoritmos de clasificación. Esta herramienta ha permitido evaluar de forma ágil el comportamiento de los modelos, analizar métricas de rendimiento y comparar enfoques sin necesidad de implementar código específico, actuando como un entorno de experimentación orientado a la toma de decisiones técnicas fundamentadas.

A partir de los resultados obtenidos en esta fase, se identificaron los modelos más adecuados para el problema planteado, destacando especialmente los modelos basados en árboles de decisión por su equilibrio entre precisión, interpretabilidad y comportamiento estable con el tamaño actual del dataset.

Una vez validado el enfoque de modelado, el proyecto avanzó hacia la fase de despliegue en un entorno Python independiente. En esta fase, los modelos entrenados han sido replicados e integrados directamente en la aplicación TrafiVision, permitiendo su utilización fuera del entorno de experimentación. Esta integración posibilita el uso del modelo dentro de una interfaz gráfica, donde el usuario puede introducir distintas condiciones de entrada y obtener una predicción del nivel de tráfico.

De este modo, Altair AI Studio se ha empleado como entorno de validación y justificación técnica del modelo, mientras que Python se ha utilizado como entorno final de implementación funcional. Esta separación entre experimentación y despliegue aporta claridad al diseño del sistema, mejora su mantenibilidad y facilita la reutilización del modelo en contextos prácticos y orientados al usuario final.

Perspectiva futura del modelado

En su estado actual, el proyecto TrafiVision ya cuenta con un modelo predictivo integrado en una aplicación gráfica funcional, capaz de estimar el nivel de tráfico urbano a partir de variables temporales, espaciales y meteorológicas. No obstante, se identifican varias líneas de evolución que permitirían mejorar y consolidar los resultados obtenidos.

Una de las principales líneas de mejora consiste en la ampliación del periodo de observación utilizando la misma infraestructura desarrollada, con el objetivo de incorporar un mayor número de registros y una representación más equilibrada de situaciones menos frecuentes, como episodios de lluvia intensa o condiciones de tráfico elevado. Esta ampliación permitiría mejorar la capacidad de generalización del modelo y reforzar su fiabilidad.

En cuanto al análisis predictivo, se contempla la optimización del modelo actual mediante el ajuste de sus hiperparámetros y la evaluación de variantes

más robustas dentro de la misma familia de algoritmos, especialmente para mejorar la clasificación de escenarios de alta congestión.

Asimismo, la interfaz gráfica desarrollada podría ampliarse con nuevas funcionalidades de visualización, como la comparación de predicciones entre distintas ubicaciones o franjas horarias, o la incorporación de representaciones gráficas que faciliten la interpretación de los resultados obtenidos por el modelo.

De este modo, TrafiVision evolucionaría desde una solución funcional de análisis y predicción hacia una herramienta más completa de apoyo a la interpretación y el estudio del tráfico urbano, manteniendo una arquitectura coherente y escalable.

Conclusión del modelado

La fase de modelado desarrollada en el proyecto TrafiVision ha permitido validar la viabilidad de aplicar técnicas de aprendizaje automático para la predicción del nivel de tráfico urbano a partir de datos reales de carácter temporal, meteorológico y contextual.

A partir del dataset generado mediante el proceso ETL, se llevó a cabo una fase de experimentación utilizando Altair AI Studio, en la que se evaluaron distintos algoritmos de clasificación supervisada. Los resultados obtenidos muestran que el conjunto de variables seleccionadas contiene información relevante para estimar el nivel de tráfico, alcanzándose precisiones cercanas al 73% con modelos basados en árboles de decisión, considerados adecuados para el volumen y las características actuales del conjunto de datos.

Posteriormente, el modelo seleccionado ha sido integrado en una aplicación gráfica desarrollada en Python, permitiendo su utilización en un entorno práctico y demostrando la coherencia entre la fase de modelado y su aplicación real. Esta integración confirma que el modelo no solo es válido desde un punto de vista teórico, sino también funcional dentro de un sistema interactivo.

El modelado ha puesto de manifiesto tanto el potencial del enfoque propuesto como sus limitaciones, especialmente en relación con el tamaño del dataset,

el desbalance entre clases y la limitada representación temporal. No obstante, estas limitaciones no invalidan los resultados obtenidos, sino que delimitan claramente el contexto en el que el modelo es aplicable en su estado actual.

En conjunto, esta fase de modelado cumple su objetivo principal: demostrar que los datos recopilados y procesados por TrafiVision permiten construir e integrar un modelo predictivo coherente y funcional, sentando una base sólida para futuras mejoras, ampliaciones del conjunto de datos y evolución del sistema hacia aplicaciones más avanzadas de análisis y apoyo a la toma de decisiones en movilidad urbana

Capítulo 7. BIBLIOGRAFIA/WEBGRAFIA

Fuentes técnicas y documentación

[1] Open-Meteo. *API Documentation: Free Weather Forecast API for Developers*. Disponible en: <https://open-meteo.com/>
Consultado en octubre de 2025.

[2] Ayuntamiento de Madrid. *Portal de Datos Abiertos: Tráfico en tiempo real y cámaras urbanas*. Disponible en:
<https://informo.madrid.es/informo/tmadrid/camaras.jsp>
Consultado en octubre de 2025.

[3] Ultralytics. *YOLOv8 Documentation — Object Detection Models*. Disponible en:
<https://docs.ultralytics.com/>
Consultado en noviembre de 2025.

[4] Python Software Foundation. *Python 3.9 Documentation*. Disponible en:
<https://docs.python.org/3.9/>

[5] Pandas Development Team. *Pandas User Guide — Data Analysis Library*. Disponible en:
<https://pandas.pydata.org/docs/>

[6] Schedule Library. *Python Job Scheduling for Humans*. Disponible en:
<https://schedule.readthedocs.io/>

[7] Requests Library. *Python HTTP for Humans*. Disponible en:
<https://requests.readthedocs.io/>

[8] Azure Machine Learning Studio (Alair). *Documentación de Azure Machine Learning*. Disponible en:
<https://learn.microsoft.com/es-es/azure/machine-learning/>

[9] Google AI Studio. *Herramienta de experimentación en IA*. Disponible en:
<https://aistudio.google.com/>

Fuentes académicas y metodológicas

[10] AENOR. AEN/CTN 157 — *Proyectos. Normas y Publicaciones*. [En línea] 2010. Disponible en:

<http://www.aenor.es/aenor/normas/ctn/fichactn.asp?codigonorm=AEN/CTN%20157>

[11] UNE 157001. *Criterios generales para la elaboración de proyectos*. Escuela Universitaria de Ingeniería de Vitoria. 2002.

[12] Universidad Europea de Madrid. *Guía de estilo y normativa para la redacción de proyectos de ingeniería*.

Disponible en:

<http://biblioteca.uem.es/es/aprendizaje-y-formacion/citas-bibliograficas-documentos>

Fuentes académicas y de aprendizaje automático

[13] Hastie, T., Tibshirani, R., Friedman, J. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, 2009.

Referencia clásica sobre modelos de clasificación y validación en aprendizaje automático.

[14] Géron, A. *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow*. O'Reilly Media, 2022.

Manual práctico sobre modelado predictivo, validación cruzada y despliegue de modelos.

[15] Scikit-learn Developers. *Model evaluation: cross-validation and metrics*.

Disponible en: https://scikit-learn.org/stable/modules/model_evaluation.html

Consultado en noviembre de 2025.

Capítulo 8. ANEXOS

ANEXO I – Criterios de clasificación y variables derivadas

Durante la fase de diseño del dataset, se establecieron una serie de criterios lógicos para convertir los datos numéricos y contextuales en variables categóricas útiles para el análisis y el futuro modelado predictivo.

Estas reglas fueron implementadas directamente dentro de los scripts de transformación y limpieza, y se aplican de forma automática a cada nuevo registro obtenido por el sistema ETL.

1. Clasificación del nivel de tráfico

El nivel de tráfico se determinó en función del **número de vehículos detectados por el modelo YOLOv8** en cada imagen capturada.

Para convertir este valor numérico en una categoría descriptiva, se establecieron los siguientes rangos:

Nº de vehículos detectados	Nivel de tráfico asignado
0 – 5	Bajo
6 – 15	Medio
> 15	Alto

Estos umbrales se definieron tras observar los resultados iniciales del modelo y su correspondencia visual con las imágenes de las cámaras.

El criterio busca un equilibrio entre la densidad visual y la legibilidad analítica del dataset, facilitando su uso en modelos de clasificación supervisada.

2. Clasificación del tipo de lluvia

La variable “lluvia” procede del valor de **precipitación en litros/m²** proporcionado por la API de *Open-Meteo*.

Dado que pequeñas cantidades no representan necesariamente lluvia perceptible, se definieron los siguientes intervalos para su categorización:

Precipitación (L/m²)	Clasificación
≤ 0.1	No llueve
0.1 – 0.3	Lluvia débil
> 0.3	Lluvia intensa

Estos valores permiten distinguir entre condiciones secas, lloviznas leves y precipitaciones significativas, las cuales influyen directamente en la variación del tráfico urbano.

3. Categorización por franja horaria

Cada registro del dataset incluye la hora exacta de captura, la cual se transformó en una **franja horaria** representativa del momento del día.

Esta variable es relevante porque el flujo de tráfico varía de forma predecible según la hora.

Las franjas establecidas fueron:

Franja horaria	Rango horario (hh:mm)	Descripción
Madrugada	05:00 – 07:59	Tráfico bajo, desplazamientos esenciales.

Mañana	08:00 – 12:59	Horas punta laborales, mayor densidad de tráfico.
Mediodía	13:00 – 16:59	Actividad intermedia, pausas laborales y comidas.
Tarde	17:00 – 20:59	Segunda hora punta de retorno a casa.
Noche	21:00 – 04:59	Menor circulación y tráfico reducido.

Este formato permite que los algoritmos de predicción puedan relacionar patrones de tráfico con momentos específicos del día, manteniendo la coherencia temporal en todos los registros.

4. Clasificación de días laborables y no laborables

Para mejorar la capacidad predictiva del modelo, se añadió una variable binaria que distingue entre **días laborables y no laborables**, basada en el calendario oficial de la Comunidad de Madrid.

Tipo de día	Criterio
Laborable	Lunes a viernes (excepto festivos).
No laborable	Sábados, domingos y festivos oficiales.

Esta variable permite detectar diferencias de comportamiento entre el tráfico diario y el de fines de semana o días festivos, que suelen mostrar patrones menos congestionados.

5. Tratamiento de variables categóricas para el modelado

Las variables categóricas generadas durante la fase de transformación (calle, franja horaria, tipo de día y clasificación de lluvia) fueron diseñadas con el objetivo de facilitar su uso posterior en modelos de aprendizaje automático.

Estas variables permiten representar información contextual compleja de forma estructurada y comprensible, evitando el uso exclusivo de valores numéricos que pueden resultar menos interpretables. Durante la fase de modelado, dichas variables se emplean como atributos de entrada, siendo tratadas internamente por las herramientas de aprendizaje automático mediante técnicas de codificación adecuadas.

La inclusión de estas variables categóricas permite que los modelos aprendan relaciones entre contexto temporal, condiciones meteorológicas y ubicación, contribuyendo a una mejor interpretación de los patrones de tráfico urbano y a una mayor estabilidad del proceso de entrenamiento.

Resumen

Los criterios de clasificación y las variables derivadas definidos en este anexo permiten transformar datos brutos procedentes de distintas fuentes en información estructurada, coherente y semánticamente interpretable. La categorización del nivel de tráfico, la clasificación de la lluvia, la segmentación por franjas horarias y la distinción entre días laborables y no laborables aportan contexto al dataset y facilitan la identificación de patrones relevantes.

Asimismo, el tratamiento de las variables categóricas se ha diseñado pensando en su uso directo en modelos de aprendizaje automático, garantizando que el dataset generado por TrafiVision sea fácilmente escalable, reutilizable y adecuado tanto para análisis exploratorios como para tareas de modelado predictivo. En conjunto, este enfoque refuerza la calidad del dataset y su utilidad como base para el análisis del tráfico urbano.

